# 本科生毕业论文（设计）

题目：基于人工智能网络的

水下无线光信号检测技术研究


姓　　名　韦子扬

学　　号　20309071

院　　系　电子与信息工程学院

专　　业　通信工程

指导教师　江明 教授


二〇二四年五月六日

# 基于人工智能网络的

# 水下无线光信号检测技术研究

# Research on Underwater Wireless Optical Signal Detection Technology Based on Artificial Intelligence Networks


学生姓名: 韦子扬

学 号: 20309071

院 系: 电子与信息工程学院

专 业: 通信工程

指导教师: 江明 教授


时间：二〇二四年五月十六日

# 学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文（设计）不包含任何其他个人或集体已经发表或撰写过的作品成果。对本论文（设计）的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文（设计）的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

作者签名:

日　　期：　　年　　月　　日

**论文题目：** 基于人工智能网络的水下无线光信号检测技术研究
**专　　业：** 通信工程
**学生姓名：** 韦子扬
**学　　号：** 20309071
**指导教师：** 江明 教授

# 摘要

水下无线信息传输（Underwater Wireless Communication，UWC）在污染监测、海洋勘探、气候变化监测、海洋学研究等方面发挥着重要作用。在 UWC 的实现方案中，水下无线光通信（Underwater Wireless Optical Communication，UWOC）由于其高吞吐量、高速率的特性，正逐步成为水下通信的主流解决方案。在水下无线通信中，由于水体的吸收、散射效应以及湍流作用，信道的复杂性显著增强。同时，受洋流、盐度分布及收发设备动态变化等多种因素的影响，信道状态信息（Channel State Information，CSI）随时间和空间变化会表现出不同的特征。上述现象使信道估计以及信道检测成为 UWOC 高速可靠传输中的难题。针对上述问题，本文研究了一种 UWOC 信道环境下的信号生成检测（Signal Generate and Detection，SGD）方案在不同水体环境中的表现并对其时间复杂度高的问题进行了改进，本文的主要贡献以及创新点总结如下：

本文面向 UWOC 场景，在现有的条件生成对抗网络（Conditional Generative Adversarial Net，CGAN）以及深度神经网络（Deep Neural Network，DNN）联合检测的 SGD 方案基础上，研究了一种基于 Siamese 网络控制器的改进方案以及一种基于循环一致性生成对抗网络（Cycle-Consistent Generative Adversarial Net，CycleGAN）转换器的替换方案。在本设计中，CGAN 的生成器被训练作信道转换器，用于生成具有 DNN 检测器所训练位置信道特性的接收符号从而实现信号检测。而 Siamese 网络被训练作信道相似度检测器，用于控制 CGAN 的线上更新过程；CycleGAN 网络则被用于在训练样本采集受限时作为 CGAN 的替换方案。传统的 DNN 信号检测方案仅依赖于线下更新过程，而使用 CGAN 与 DNN 进行联合检测的方案虽然解决了这一问题，但带来了复杂度的提升以及样本采集的成本增加，本设计采用 Siamese 网络控制线上更新过程，实现了更低的时间复杂度性能，并研究了 CycleGAN 替换 CGAN 网络以降低样本采集成本的可行性。此外，为了实现 CGAN 的上述功能，本文提出了一种分段训练的方案，将常规的无监督对抗作为前半段的训练目标，而后半段的训练将信道转换中同一比特信息经过两信道的接收结果作为训练转换目标，即使用均方误差（Mean-Square Error，MSE）进行生成器的监督训练；为了实现 Siamese 网络的功能，将前半段的训练目标设置为传统的相似度拟合，将后半段训练目标设置为收敛步数与预测结果的 MSE，从而进行有目标的监督训练。仿真结果表明，在 CSI 变化的 UWOC 场景中，本 SGD 方案可用于实现信号的生成与检测，对比基于导频的传统检测方法最小二乘估计（Least Square，LS）以及线性最小均方误差估计（Linear Minimum Mean Square Error，LMMSE）

以及不考虑 CSI 变化的 DNN 检测器方案有明显的性能增益，在时间复杂度上也有较好的表现，不仅如此，基于 CycleGAN 的替换方案相比同等数量训练样本的 CGAN 方案以及同等数量导频的 LS、LMMSE 方法均有可观的性能增益。

**关键词：** 水下无线光通信（UWOC）；深度神经网络（DNN）；条件生成对抗网络（CGAN）；Siamese 网络；循环一致性生成对抗网络（CycleGAN）

**Title:** Research on Underwater Wireless Optical Signal Detection Technology Based on Artificial Intelligence Networks
**Major:** Communication Engineering
**Name:** Ziyang Wei
**Student ID:** 20309071
**Supervisor:** Prof. Ming Jiang

# ABSTRACT

Underwater Wireless Communication (UWC) plays an important role in pollution monitoring, marine exploration, climate change monitoring, and oceanographic research. In the implementation of UWC, Underwater Wireless Optical Communication (UWOC) is gradually becoming the mainstream solution for underwater communication due to its high throughput and high-speed characteristics. In underwater wireless communication, due to the absorption, scattering effects, and turbulence of water, the complexity of the channel is significantly enhanced. At the same time, affected by factors such as ocean currents, salinity distribution, and dynamic changes of the transmitter and receiver equipment, the Channel State Information (CSI) varies with time and space, showing different characteristics. The above phenomenon makes channel estimation and channel detection a challenge in UWOC high-speed and reliable transmission. In response to the above issues, the performance of a Signal Generation and Detection (SGD) scheme for the UWOC channel in different water environments is investigated in this thesis, and its high time complexity is improved. The main contributions and innovative points of this thesis are summarized as follows:

In the context of the UWOC scenario, an improved scheme based on a Siamese network controller and a replacement scheme based on Cycle Consistent Generative Adversarial Net (CycleGAN) converter are studied in this thesis, which is built on the existing Conditional Generative Adversarial Net (CGAN) and Deep Neural Network (DNN) joint detection SGD solution. In this design, the generator of CGAN is trained as a channel converter to generate receiving symbols with channel characteristics of the position trained by DNN detector, thereby achieving signal detection. The Siamese network is trained as a channel similarity detector to control the online update process of CGAN. The CycleGAN network is used as a replacement for CGAN when training sample collection is limited. The traditional DNN-based signal detection scheme relies solely on offline update processes. Although the joint detection scheme using CGAN and DNN addresses this issue, it introduces increased complexity and the cost of sample collection. This scheme employs a Siamese network to control the online update process, achieving lower time complexity performance, and investigates the feasibility of replacing the CGAN with a CycleGAN network to reduce the cost of sample collection. In addition, in order to achieve the above

functions of CGAN, this paper proposes a segmented training scheme, which uses conventional unsupervised adversarial training as the target for the first half, and training for the second half uses the received results of the same bit information in channel conversion through two channels as the training conversion target, that is, using Mean Square Error (MSE) for supervised training of the generator. And in order to achieve the functionality of the Siamese network, the training objective for the first half is set to traditional similarity fitting, and the training objective for the second half is set to the MSE of convergence steps and prediction results, thus conducting targeted supervised training. The simulation results show that in UWOC scenarios with CSI changes, this SGD scheme can be used to achieve signal generation and detection, and has significant performance gains compared to traditional pilot based detection methods such as Least Square (LS), Linear Minimum Mean Square Error (LMMSE), and DNN detector schemes without considering CSI changes, and also performs well in terms of time complexity. Moreover, the replacement scheme based on CycleGAN has significant performance gains compared to CGAN schemes with the same number of training samples, as well as LS and LMMSE methods with the same number of pilots.

**Keywords:** Underwater Wireless Optical Communication (UWOC), Deep Neural Network (DNN), Conditional Generative Adversarial Net (CGAN), Siamese network, Cycle Consistent Generative Adversarial Net (CycleGAN)

# 目录


第 1 章 引言 . . . . . 1
1.1 选题背景与意义 . . . . . 1
1.2 国内外研究现状和相关工作 . . . . . 3
1.3 本文的研究内容与主要工作 . . . . . 7
1.4 本文的论文结构与章节安排 . . . . . 7

第 2 章 系统模型 . . . . . 9
2.1 水下无线光通信模型 . . . . . 9
2.2 DCO-OFDM 系统模型 . . . . . 12
2.3 SGD 线下训练以及线上更新流程 . . . . . 15
2.4 DNN 检测器模型 . . . . . 20
2.5 CGAN 信道转换与检测器模型 . . . . . 21

第 3 章 系统改进方案 . . . . . 28
3.1 改进的 SGD 方案线下训练以及线上更新流程 . . . . . 28
3.2 Siamese 线上更新控制器模型 . . . . . 30
3.3 CycleGAN 信道转换与检测器 . . . . . 34

第 4 章 仿真验证与测试 . . . . . 39
4.1 仿真设置 . . . . . 39
4.2 基于 CGAN-DNN 联合检测的 SGD 方案在不同水体中的性能 . . . 44
4.3 基于 Siamese 网络的线上更新性能 . . . . . 49
4.4 CycleGAN-DNN 联合检测 SGD 方案在训练样本减少时的性能 . . . 54

第 5 章 总结与展望 . . . . . 57
5.1 工作总结 . . . . . 57
5.2 研究展望 . . . . . 58

参考文献 . . . . . 59

致谢 . . . . . 65

# 第 1 章 引言

## 1.1 选题背景与意义

随着人类社会的快速发展和科技的持续创新，陆地以及太空已逐渐无法满足人类的资源需求。研究表明，地球表面的三分之二被水体覆盖。在数千年的历史长河中，人类对海洋的探索从未停歇。然而，近年来，面对全球气候变迁和资源短缺等问题，人们逐渐开始关注水下资源的开发，研究学者对海洋探测系统的兴趣日益浓厚。水下无线信息传输（Underwater Wireless Communication，UWC）技术在海洋探测系统中有着不可或缺的作用[1]，因此近年来受到了广泛的关注。

UWC 是指在水下环境中，通过无线技术传输信息的过程。由于水下的特殊环境，水下无线通信面临着许多挑战，如水的吸收、散射、多径效应等，这些都导致了信号衰减和传播距离的限制。尽管如此，水下无线通信在海洋勘探、水下军事、水下传感器网络、水下无人机通信等领域仍然是至关重要的。水下无线通信主要可以分为以下几种技术：

1）水下射频（Radio Frequency，RF）通信。水下 RF 通信使用电磁波进行信息传输。这种技术设备成熟，易于集成，然而在海水中衰减系数较大，传输距离和速率受到很大的限制，不仅如此，在传输数据时，需要更大的功率或更大尺寸的接收天线[2]；

2）水下声波通信（Underwater Wireless Acoustic Communication，UWAC）。UWAC 是利用声波在水中传播的特性进行通信。声波在水下的传播距离较远，但速度较慢，且容易受到水体动态变化的影响，从而极大地限制了传输数据的带宽[3]；

3）水下无线光通信（UWOC）。与传统的无线电波通信不同，UWOC 采用光波作为信息载体，通过发射器将光信号发射到水中，然后由接收器在水下接收并解调光信号，从而实现数据传输。UWOC 技术有高带宽和高速传输的潜力，其凭借丰富光谱带宽以及适合高速数据传输的特性成为了实现高速率以及高带宽稳定水下传输的重要技术。在 6G 通信技术的未来愿景中，UWOC 作为实现空天地海一体化通信的关键技术，将极大地增强水下区域的通信覆盖范围。

目前对 UWC 技术的研究中，UWAC 领域占据着主要的部分，与之相比，UWOC 技术主要具有以下几方面的优势：

1）更高的数据速率。与水声相关的典型频率在几十赫兹到几兆赫兹之间，因此水下声学链路的传输数据速率相对较低，一般在 kbps 数量级[2]，相比之下，UWOC

可以在几十米的中等距离上实现 Gbps 数量级的数据速率[4]，在通信的数据速率上优势更大；

2）更低的链路延迟。声波在水中的传播速度较慢，据测量，该速度在 20 摄氏度的纯水中约为到 1500m/s，因此水下的声学链路会遭受严重的通信延迟，该延迟通常达到数秒。因此，UWAC 难以满足要求实时大数据传输的应用需求。相比之下，由于光波在水体中的传播速度显著超越声波，典型值可达到 $2.25 \times 10^8$m/s，因此 UOWC 系统中链路延迟问题相对较小，可实现实时的通信；

3）更低的部署成本。水声通信大多数采用广播方案实现，因此其发射机与接收机通常具有体积大、成本高以及能耗大的缺点，而 UWOC 系统中的器件（如 LED 和激光二极管）具有功耗较低、成本较低以及体积较小的特点，更适合进行大规模的通信网络部署；

4）更高的保密性。相对于水声通信的广播方案，UWOC 由于功率较低且损耗较大，因此大多数采用强指向性视距（Line-of-Sight，LOS）传输，此时通信系统为密闭结构，难以进行窃听。

综上所述，UWOC 技术凭借其高带宽、低延时、低成本、高保密性等独特优势，成为实现水下通信的有效手段。该技术有望促进海洋资源的开发、深海探索以及水下装备的智能化发展，对国家海洋战略的实施具有重要意义，因此，对 UWOC 系统中的通信技术展开深入研究迫在眉睫。然而，实现 UWOC 是一项极具挑战性的任务，其深入发展及全面普及仍面临着许多问题与挑战：

1）吸收损耗。水分子由氢原子与氧原子组成，具有极性，当光束通过 UWOC 信道时，水分子与光波会发生相互作用，部分光子被水体吸收导致光束能量减少，转化为水分子的内能。光束能量的减弱会导致接收机接收有效信号能量减弱，降低信噪比，从而使信号恢复算法误码率提高，降低通信质量；

2）散射效应。光束通过 UWOC 信道时，水分子与光发生相互作用导致光子发生方向变化与能量改变，该过程称为散射效应。这种随机的方向与能量的改变导致接收机捕获的能量减少，同时还可能导致从发射机到接收机之间有多条传播路径，即多径效应，从而带来符号间的干扰（Inter Symbol Interference，ISI），极大地降低了信号恢复算法的可靠性；

3）湍流效应与气泡。湍流是水体流动不稳定性导致的随机波动，它会引起光波的强度、相位和传播路径的随机变化，从而严重影响光波的传输，导致通信信号的衰减和失真。在 UWOC 系统中，湍流可能由水下流动、温度和盐度梯度引起[5]，它们都会对光波的传播路径产生不规则的扰动，从而降低通信的质量和稳定性。

## 1.2 国内外研究现状和相关工作

近年来，有关水下无线光通信技术的研究正在不断推进，UWOC 系统逐渐从军用普及到部分商用情景，然而距离全面商用依然有很大的距离。本节将重点介绍国内外对水下无线光通信技术的研究成果。

### 1.2.1 传统水下无线光通信技术研究

基于光的水下通信技术 UWOC 自 20 世纪 60 年代以来不断受到通信研究人员的密切关注。1963 年，美国的 Scripps 海洋研究所能见度实验室研究人员 Duntley 在研究中发现，海水中蓝波段与绿波段的光较其他波段光衰减速度极慢，从而提出了对整个 UWOC 技术产业影响巨大的蓝-绿传输窗口[6]，奠定了 UWOC 技术的研究方向。三年后，Gilbert 等人通过实验验证了水的吸收光谱在蓝绿光波段下达到最小值，证明了水下蓝绿光通信的可行性[7]。在接下来的时间里，研究学者们不断对 UWOC 技术中的发射模块以及接收模块进行材料以及结构上的改进，从而大幅度提高 UWOC 的通信速率。2006 年，Farr 等人在水下发光二极管（Light Emitting Diode，LED）光通信链路中，使用半球形 PMT 作为接收模块进行全向检测，从而实现了通信速率为 10Mbit/s 的 10m 低速通信[8]。2008 年，Hanson 等人利用蒙特卡罗的仿真方法模拟搭建了 1Gbit/s 的 2m 清水激光二极管（Laser Diode，LD）高速光通信链路[9]。2016 年，国立台北工业大学光电工程研究所的研究人员 Lu 等人第一次采用两阶段注入锁定技术来改善 UWOC 系统的传输性能，使用 16 正交幅度调制（Quadrature Amplitude Modulation，QAM）-正交频分复用的调制方法，在 8m 长的水下链路上获得了 9.6Gbit/s 的稳定高通信速率[10]。不仅在通信速率方面，学者们还在 UWOC 通信距离方面进行了深入的研究。2021 年，中国科学院无线光通信重点实验室的研究人员 Tu 等人使用单模尾状 520nm 的 LD 和雪崩光电探测器构建了 UWOC 系统，利用 QAM-OFDM 信号的细频率粒度和高频谱效率规避了绿色 LD 频率响应不均匀，不适合高速传输的难题，在 130m 的水下无线光信道上实现了低成本，高鲁棒性的 1Gbit/s 通信[11]。

要想实现稳定高效的水下无线光通信，不仅仅需要信号“传得快”、“传得远”，还需要在通信过程中辅以一定的算法，让信号“传得准”。对于传统的水下光通信信道估计与信号检测的研究，目前，研究学者们正在逐步将成熟的地面通信技术迁移到 UWOC 中以降低水下可见光通信中的误码率，使通信系统高效稳定运作。2020 年，中山大学的 Chen 等人为了解决 UWOC 中的时变非线性信道估计问题，提出了一类用于分数采样光正交频分复用（Optical Orthogonal Frequency Division

Multiplexing，OOFDM）辅助的贝叶斯信道估计算法，该算法基于 Sherman-Morrison 公式，利用了信道协方差和自相关矩阵在延迟域的秩一结构特性，在适度的计算复杂度下实现了优越的性能[12]。2022 年，在亚洲通信与光子学会议和国际信息光子学与光通信会议上，Liu 及其团队提出了一种改进的基于离散傅里叶变换的可变平滑方程信道估计算法，该算法在传统的基于离散傅立叶变换的估计中检测重要的信道抽头，并应用由变量平滑方程计算的自适应噪声阈值，从而进一步抵抗信道噪声带来的影响。以达到优于传统基于离散傅立叶变换估计的归一化均方误差，提高传输准确率[13]。随后，他们还提出了一种基于压缩感知的均匀分布导频信道估计算法，该算法根据信噪比选择噪声阈值去除无用的信道抽头。与离散傅里叶变换估计和传统的基于压缩感知的估计相比，该算法在没有噪声阈值计算器和信道抽头检测器的情况下具有更好的性能，在较低的计算复杂度下实现了 UWOC 中较低的归一化均方误差[14]。

综上所述，基于传统通信算法的 UWOC 技术在信道估计以及信号检测领域目前仍处于较早期的研究阶段，不仅如此，上述方案虽然提升了 UWOC 系统的误码率性能，但与理想 CSI 仍有较大差距，存在改进的空间。

### 1.2.2 基于机器学习的水下无线光通信技术研究

随着计算机算力的不断提高，近年来，机器学习（Machine Learning，ML）逐渐进入人们的视野，机器学习有强大的特征提取能力以及抗干扰能力，在高度复杂与不确定的水下环境中具有天生的优势。在水下无线通信中，机器学习技术主要应用于信号处理、信道估计、调制解调等方面。2021 年，Zhang 及其团队对于水下通信中的调制分类进行了研究，分别将支持向量机（Support Vector Machine，SVM），k-邻近算法（k-Nearest Neighbor，KNN）以及分类回归树（Classification and Regression Tree，CART）引入了基于特征的自动调制分类系统中对 BPSK，QPSK 以及 2FSK 等多种调制方法所获得的接收信号进行调制分类，对比传统的自动调制分类算法获得了较大的准确率提升[15]。同年，李晓记及其团队将 SVM 信号检测方法用于直流偏置光正交频分复用（DC biased optical OFDM，DCO-OFDM）水下 LED 可见光通信系统中，将信号的幅度以及相位作为数据集特征，通过网格搜索与交叉验证方法得到最优 SVM 模型，从而训练 16QAM 调制中 4 个基于比特位的 SVM 用于映射到发射信号域中，实现了相较于直接检测最小均方误差方法的较大误码率增益，提高了接收信号检测的准确性[16]。2022 年，张仲丹及其团队设计了一种基于 AdaBoost 算法的解调器应用于 UWOC 系统中，该算法迭代地训练一系列弱分类器并将它们组合成一个强分类器，通过自动调整弱分类器的重要性，使

模型整体性能得到提升，从而实现了较高于传统 SVM 方法的解调准确率[17]。次年，龙倩倩等人利用粒子群算法优化 SVM 分类器并应用于 UWOC 系统的调制分类中，降低了 SVM 参数寻优所需要时间的同时达到了较高的分类准确率[18]。2024 年，长春理工大学的叶鹏飞等人采用无监督学习的 k-means 星座解调器在信号检测阶段进行除信道估计外的二次均衡，从而小幅降低了误码率，提高了通信的可靠性[19]。

随着机器学习技术的不断发展，人们逐渐发现传统的 ML 需要人工构造特征用于机器计算，对比于深度学习（Deep Learning，DL）技术的自适应特征效率低下，不仅如此，DL 还能通过训练主动适应复杂多变的环境，在复杂多变的 UWOC 信道处理中有更大的潜能。2021 年，Zhang 及其团队将传统的 Q-Learning 方法与神经网络进行结合，提出了一种基于强化学习的多智能体 Deep-Q 网络算法，在这个设计中，每个发射器作为一个代理与通信环境进行交互，以信道容量为训练目标进行 Deep-Q 网络的训练从而最大化该目标取值，从而在无需进行收发机的信息交换的前提下以训练时间成本为代价实现了较高的信道容量[20]。而对于使用深度学习网络进行信道估计以及信号检测方面，近年来相关的研究也在稳步推进。2018 年，Ye 及其团队首次将深度学习应用于通信中的信号检测，提出基于 DNN 隐式估计信道状态信息并直接恢复传输的符号的接收机，并将该接收机应用于采用 OFDM 调制的 UWOC 系统中，其性能与 LMMSE 估计器相当，并在导频缺失，省略循环前缀等情况下拥有更高的鲁棒性[21]。然而该方案由于子载波的数量不同，DNN 被分成了几个小的部分，这导致了算法高度的时间与空间复杂性，该方案在 2021 年由石佳及其团队引入了基于 OFDM 的 UWOC 系统中并得到验证[22]。2022 年，重庆邮电大学的陈勇等人将梯度集中化的方法应用于上述 DNN 信号检测方案中，通过梯度的零均值化，减少了不同权重更新之间的相互影响，从而实现了更精确的训练以及对于 CP 缺失等条件的更高鲁棒性[23]。2020 年，Jiang 及其团队提出了一种新的深度学习辅助信号检测方案，将双级联的多层感知（Multilayer Perceptron，MLP）网络集成到接收器中。第一个子网络作为信道补偿块，第二个子网络作为解调器，从而在降低网络复杂度的基础上提高了信号检测的准确率，获得了较低的误码率[24]。然而以上三种方案均未能实现 CSI 随时间改变时的有效更新，仅能针对有限的固定信道进行信号恢复，在 UWOC 中由于多变的信道环境，其实际部署效果较差。2021 年，中山大学的 Lu 利用深度 DNN 将信道估计与信号检测结合起来，设计了一种基于 DL 的联合信道分类、信道估计和信号检测方案。该方案利用 DNN 通道分类器离线训练，从而提取通道特征，并在部署时在线识别和分类水体类型，从而产生优化的估计组合权值对各个分类器的输出结果进行加权，以提

高时变 UWOC 信道下的信道估计与信号检测性能[25]。该设计首次提出对 UWOC 的时变信道进行线上处理，使用通道分类器为针对每种信道的编码解码器进行权重赋值，使基于每种信道训练的信号检测器的结果都能被充分考虑，从而降低了在未训练信道中进行通信的误码率，同年，他还提出了一种基于 CGAN 的水下无线光通信接收机，利用 CGAN 的对抗生成特性实现信号从当前信道到训练信道的特征转换，从而使 DNN 检测器可在不同 UWOC 信道中进行精确解调，该方案在较低的空间杂度下可实现比传统 LS 以及 LMMSE 方案更优的误码率[26]。然而，该方案存在导频冗余以及时间复杂度较高等缺点，不仅如此，鉴于 UWOC 系统数据采集成本高昂，基于上述深度学习网络的信道估计与信号检测方案需要大量线下训练样本，其实现过程面临着额外的经济负担。2022 年，Wang 及其团队在双级联 MLP 的基础上引入了元学习的训练方法，使用内循环与外循环的双层训练对双级联 MLP 网络进行权重的迭代更新，使其能够获得不同水质类型光通道的一般特征，使其能够快速适应水下通道特征的未知变化，实现最佳接收。从而对比传统的深度学习方案获得更强的学习能力、更快的收敛速度以及更低的误码率[27]。然而该方案需要对 MLP 进行多次训练，线下训练时间成本高，且线上更新对 MLP 进行迭代更新，时间复杂度较高。

综合上述文献，我们可以发现，目前对于 UWOC 信道估计与信号检测的深度学习解决方案存在四类主要的问题，1）由于水下信道较为复杂，因此对于 UWOC 系统中的信号检测算法，目前方案的误码率性能仍与理想 CSI 存在差距，仍有进一步优化的可能；2）UWOC 信道具有时间变化特性，基于深度学习的信号检测方案若无法实时进行线上更新，则 CSI 状态的改变会导致方案在实际部署中的误码率大大提升，影响通信质量；3）在实现线上更新的信号检测或信道估计方案中，由于使用复杂的线上更新网络进行控制，其时间复杂度较高，影响了通信的即时性；4）基于深度学习的信号检测或信道估计方案需要大量训练样本支撑，而 UWOC 中信号样本采集成本较高，在实际部署中开销较大。

综上所述，目前基于 DL 的水下信道接入、信道估计以及信号检测等水下通信技术正在不断完善与进步，UWOC 技术在通信距离，通信速率以及信号准确率等方面都在快速发展。然而，目前基于 DL 的 UWOC 技术处于发展阶段，尚未达到成熟水平，未考虑 CSI 变化与样本采集成本等实际问题，距离全面普及依然有不小的距离。然而，考虑到 UWOC 信道较复杂的多径和时变特性，传统方法可能较难满足 UWOC 场景的需要，而 DL 技术因其卓越的特征提取能力和自适应特性，为 UWOC 系统的信号检测技术研究开辟了新的解决思路，有望在这一领域发挥重要作用。

## 1.3 本文的研究内容与主要工作

本文对基于 DL 的 UWOC 系统信号检测技术展开研究，针对上述 UWOC 中的 CGAN-DNN 联合检测方案进行了验证，并分别提出了一种低时间复杂度、低训练样本需求的改进方案。具体而言，本文首先在不同水体中验证了应用于 CSI 变化场景的基于 DL 技术中 CGAN 的信号生成与检测设计的可行性，接着针对该设计线上更新过程时间复杂度较高的问题提出了一种基于 Siamese 网络的线上更新控制器。使用 Siamese 网络对信道条件进行分析并控制 CGAN 线上更新的过程，避免了线上更新运行步数的冗余，从而实现了时间复杂度的降低。不仅如此，本文还对水下信号样本采集困难的现状对 CGAN 提出了一种基于 CycleGAN 的替换方案，通过无监督训练减少了信号样本的数量，降低了训练样本采集的开销。针对所提出的设计方案，本文基于 MATLAB® R2020b 仿真平台，通过仿真对其性能进行了验证和分析。

## 1.4 本文的论文结构与章节安排

本文共分为五章，各章节内容安排如下：

第一章：本章为引言部分，首先介绍了本论文的选题背景以及意义，接着针对本文研究的基于机器学习的 UWOC 系统信号检测技术相关的研究现状进行梳理、介绍与总结，并基于此介绍本文的主要研究内容以及工作，最后本章还对本文的结构与安排进行说明；

第二章：本章对设计中的基础系统模型进行了介绍，包括水下无线光通信模型，DCO-OFDM 系统模型，基于 CGAN-DNN 联合检测的 SGD 实现流程，DNN 检测器模型，CGAN 信道转换与检测器模型，并对其在系统中的具体功能以及预期效果进行了介绍；

第三章：本章对系统中存在的问题进行了改进，并对改进后的系统工作流程进行了介绍，包括改进的 SGD 方案线下训练以及线上更新流程，Siamese 线上更新控制器模型以及 CycleGAN 模型介绍；

第四章：本章对设计进行了基于蒙特卡洛方法的仿真，对 DNN 检测器、CGAN 信道转换与检测器以及 Siamese 线上更新控制器以及 CycleGAN 信道转换与检测器的误码率性能进行了对比，并比较了 Siamese 线上更新控制器所带来的复杂度变化，体现了 CGAN-DNN 联合检测的 SGD 方案相比于传统的 LS 以及 LMMSE 方法的性能优势以及 CycleGAN-DNN 联合检测方案在训练样本减少时更高的鲁棒性；

第五章：对本文工作进行了总结，并指出工作中的不足之处，对该课题的前景进行了展望。

# 第 2 章 系统模型

本研究工作基于CGAN信道转换与检测器-DNN检测器联合工作的水下DCO-OFDM 调制系统进行，因此本章将重点对该系统进行介绍。其中包括水下无线光通信模型，DCO-OFDM 系统模型，DNN 检测器模型以及 CGAN 信道转换与检测器模型。

## 2.1 水下无线光通信模型

在介绍本文工作前，先对 UWOC 系统的信道进行建模，从而为后续的内容奠定基础。在 UWOC 系统中，信息主要以光的形式在水下传输。光在海水中会受到许多不确定因素的影响，如1.1节所述的吸收损耗，散射损耗，湍流效应以及气泡等。由于水下信道非常复杂，因此本节主要围绕以下两个方面进行 UWOC 信道的建模：由吸收和散射效应导致的信号衰落以及时变的随机湍流衰落。

### 2.1.1 吸收和散射效应导致的信号能量衰减

吸收系数和散射系数是决定水下光衰减的两个主要参数。其中，水对光的吸收是一种能量传递的过程，在此过程中，发射的光子失去能量并转化为热能等其他形式的能量，光束能量的减弱会导致接收机接收信号能量减弱[28]，从而导致 UWOC 的链路距离受限；而散射是光与水的分子和原子相互作用导致光子发生方向变化与能量改变的结果，由于光学孔径的大小是有限的，散射会使光束扩散，导致接收器收集到的光子数量减少，这将导致系统的信噪比下降，不仅如此，散射效应还会导致多径色散，从而在接收符号中引入码间干扰（Inter Symbol Interference，ISI）。

为了介绍吸收与散射系数，我们引入了如图2-1所示的水体模型。

如图2-1，我们假定图中的立方体为UWOC 信道载体的一部分，其厚度为 $\Delta D$，体积为 $\Delta V$，并假设有一束波长为 $\lambda$ 的准直光束照射其表面。我们定义光信号功率由入射光功率 $P_I$，水体吸收功率 $P_A$，散射光功率 $P_S$ 以及最终透过水体传输的光功率 $P_T$ 组成[28]，其关系式为：

$$P_I = P_A + P_S + P_T \tag{2.1}$$

基于式2.1，我们定义吸收功率与入射功率之比 $P_A/P_I$ 为吸收率，同理，定义

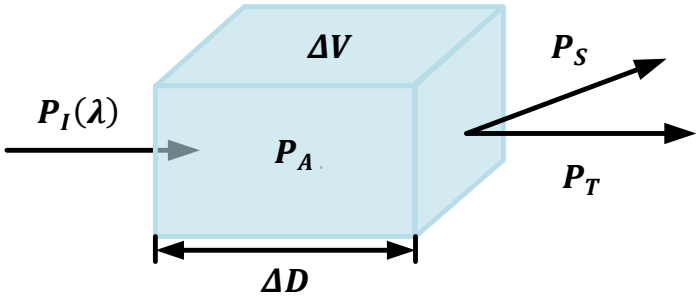


图 2-1 水体模型[28]

表 2-1 不同水体中 $a(\lambda)$，$b(\lambda)$，$c(\lambda)$ 的典型值[30]

| 水体名称 | $a(\lambda)$ | $b(\lambda)$ | $c(\lambda)$ |
|---|---|---|---|
| 纯净海水 | 0.053 | 0.003 | 0.056 |
| 清澈海水 | 0.114 | 0.037 | 0.151 |
| 沿海海水 | 0.179 | 0.219 | 0.398 |
| 浑浊港口水 | 0.295 | 1.875 | 2.17 |

散射光功率与入射光功率之比 $P_S/P_I$ 为散射率，当 $\Delta D$ 足够小时，有吸收率以及散射率的公式如下：

$$a(\lambda) = \lim_{\Delta D \to 0} \frac{P_A}{P_I \Delta D} \tag{2.2}$$

$$b(\lambda) = \lim_{\Delta D \to 0} \frac{P_S}{P_I \Delta D} \tag{2.3}$$

其中，$a(\lambda)$ 是水的吸收率，$b(\lambda)$ 是水对光的散射率，其值与照射光束波长 $\lambda$ 有关，在水下光学中，吸收和散射的总体衰减效应可以用衰减系数 $c(\lambda)$ 来描述，$c(\lambda)$ 可以表示为[29]：

$$c(\lambda) = a(\lambda) + b(\lambda) \tag{2.4}$$

式中，$c(\lambda)$ 的单位为 $m^{-1}$，其意义为每 1 米内水对光能量的衰减比例。

衰减系数 $c(\lambda)$ 随水体类型与水深度不同发生变化，表2-1给出了四种主要水体相关的 $a(\lambda)$，$b(\lambda)$，$c(\lambda)$ 的典型值。在纯净海水中，光的吸收是光传播主导的限制因素，不仅如此，由于其低散射特性，光束可以保持较为集中的传播。而在清澈海域中，溶解物质的增加会导致散射现象增加。沿海海水中，浮游生物、碎屑和盐类等物质共同作用成为影响光传播的主要原因。在港口等浑浊水域中，溶解和悬浮物质的浓度相对而言达到峰值，从而显著地减弱了光线的穿透能力[30]。

鉴于 UWOC 系统成本较高，为了在计算机上实现更精确的信道建模，从而准确验证算法的可行性、减少测试系统实际搭建所需要的开销，2008 年，Cochenour 及其团队提出了一种利用辐射传输方程（Radiative Transfer Equation，RTE）进行信道建模的理论。RTE 是描述光在介质中传播时，由于散射和吸收而发生能量转移的数学模型[31]。这个方程在光学、大气科学、海洋学、医学成像等领域都有广泛的应用。RTE 考虑了光子在传播过程中可能经历的多次散射和吸收事件，以及这些事件对光强度分布的影响。相比于比尔-朗伯定律[32] 仅对光在均匀介质中传播生效，RTE 不仅包含了光的衰减，还包含了光的散射。这使得 RTE 能够更准确地描述光在复杂介质（如含有悬浮颗粒的水体）中的传播。在该文献中，Cochenour 等人采用了小角度近似来简化 RTE。小角度近似方法假设散射主要发生在小角度范围内，并且没有来自大角度散射事件的贡献。这种近似使解析求解复杂的 RTE 成为可能，从而更好地应用于水下无线光通信链路的性能预测。

然而，复杂的解析方法通常意味着大量人工以及时间成本的投入，因此，在实际的工程应用中，许多学者使用蒙特卡洛仿真法（Monte Carlo，MC）进行 UWOC 的研究[33]。蒙特卡洛方法是一种基于随机抽样来解决数学和物理问题的计算算法。这种方法通过模拟随机事件的多次实验来获得问题的数值解。在光学领域，蒙特卡洛方法被广泛应用于光的传播、散射和吸收等复杂现象的模拟。在 UWOC 中，蒙特卡洛方法通过模拟大量光子在水体中的传播路径，包括它们的吸收以及散射事件，从而统计分析接收端的光强分布和信道特性。蒙特卡洛方法具有灵活性，精确性以及适用于并行计算等优点，是当今主流的 UWOC 信道建模方法。

### 2.1.2 时变的随机湍流衰落

在 UWOC 系统中，湍流指的是由温度、压力和盐度波动引发的水折射率迅速变化的现象[5]。由于水下湍流与大气湍流具有相似的效应，因此，大多数水下光的湍流模型构建都以自由空间光通信中的大气湍流模型作为参考。文献[34] 采用大气湍流的对数正态分布模型描述水下湍流进行建模，较为准确的阐述了 UWOC 信道的湍流衰落特性。

具体地说，湍流引起信号衰落幅度的变化可表示为：

$$\alpha = e^{2\xi} \tag{2.5}$$

其中，$\alpha$ 具有对数正态分布的概率密度函数[35]（Probability Density Function，PDF）：

$$f(\alpha)=\frac{1}{2\alpha\sqrt{2\pi{\sigma_\xi}^2}}e^{-\frac{ln\alpha-2{\mu_\xi}^2}{8{\sigma_\xi}^2}} \tag{2.6}$$

式中，$\xi$ 服从均值为 $\mu_\xi$，方差为 ${\sigma_\xi}^2$ 的正态分布。为了使该对数正态分布保持归一化 $E[a]=1$，可以令 $\mu_\xi=-{\sigma_\xi}^2$[35]，其中 ${\sigma_\xi}^2$ 可以通过下式计算：

$${\sigma_\xi}^2=0.25ln(1+{\sigma_I}^2),\quad 0.1\le {\sigma_I}^2<1 \tag{2.7}$$

式中，${\sigma_I}^2$ 是平面波和和球面波的闪烁指数[36]。

## 2.2 DCO-OFDM 系统模型

本节主要对设计中 UWOC 系统采用的调制-解调方案进行整体介绍，其中包括传统的 DCO-OFDM 系统模型以及本设计中基于 DCO-OFDM 系统模型 SGD 实现流程。

### 2.2.1 传统 DCO-OFDM 系统模型

在本设计中，我们基于 DCO-OFDM 调制方案对 UWOC 强度调制/直接探测（Intensity Modulated/Direct Detection，IM/DD）系统进行仿真[37]，同样地，本方案也适用于其他的 OOFDM 调制方案，如 ACO-OFDM，ADO-OFDM[37]，UOFDM[38]等。

DCO-OFDM 系统的基本系统模型如图2-2所示，其实现流程如下：

图2-2上半部分为DCO-OFDM 系统的发射机部分，发信用户发送的比特信息 **b** 首先由串行数据变为并行数据，从而使发射机充分高效地进行调制，接着并行数据被调制并映射到星座图上，产生 $N\times1$ 维的复数码流 $\mathbf{X}=[\mathbf{X}_{[0]},\mathbf{X}_{[1]},\mathbf{X}_{[2]},\ldots,\mathbf{X}_{[N-1]}]$，其中 $N$ 是该方案中 OOFDM 的子载波数目。接着 **X** 被输入到快速傅里叶反变换（Inverse Fast Fourier Transform，IFFT）计算中，由于无线光通信中 IM/DD 的技术要求，**X** 受埃尔米特共轭对称关系约束，如式2.8所示：

$$\begin{cases}\mathbf{X}_{[m]}=\mathbf{X}^*_{[N-m]}, & 0<m<\frac{N}{2}\\ \mathbf{X}_{[m]}=0, & m\in\{0,\frac{N}{2}\}\end{cases} \tag{2.8}$$

式中，$(\cdot)^*$ 代表复共轭运算。由于输入呈埃尔米特共轭对称分布，因此 IFFT 的输出信号为实数。

在本文中，我们规定离散频域的信号采用大写字母表示，而与之对应的离散时域信号则使用小写字母标识。经过 IFFT 后，复数码流 **X** 变为 $N \times 1$ 维的时域实数信号 **x**，基于傅里叶变换的特性，时域信号 **x** 可表示为：

$$\mathbf{x}_{[k]} = \frac{1}{N}\sum_{m=0}^{N-1}\mathbf{X}_{[m]}e^{j\frac{2\pi km}{N}} \tag{2.9}$$

式中，$\mathbf{X}_{[m]}$ 是第 $m$ 个子载波上的复数码流符号，$\mathbf{x}_{[k]}$ 是时域信号 $k$ 的第个子样本。由于埃尔米特共轭对称，DCO-OFDM 中携带数据的子载波的数量为 $\frac{N}{2}-1$。进行复共轭变换后，对原始时域信号 **x** 进行添加循环前缀（Cyclic Prefix，CP），接着将信号由并行转换到串行以便发射终端进行信号发送，由于输入为数字信号，需将其转换为模拟信号进行发射，因此需要进行数字/模拟（Digital/Analog，D/A）信号转换，对转换后的模拟信号进行低通滤波后即可得到时域发射信号 $x(t)$，对该信号采用 DCO-OFDM 处理标准进行直流偏置、零点削波后即可载入到发射终端 LED 进行信号的发射。在本设计中，我们假设一个理想的光调制器，使输出光信号的强度与输入电流成正比。所得到的输出光信号通过平坦信道 $h(t)$ 传输，其中，影响信号的散粒噪声为加性高斯白噪声 $n(t)$。

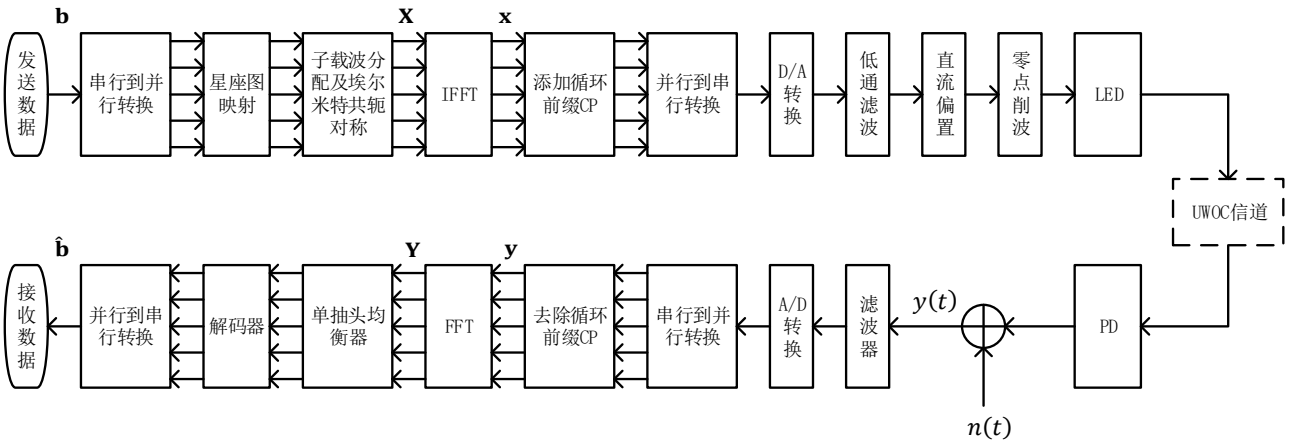


图 2-2 传统 OFDM 系统模型框图

图2-2下半部分为 DCO-OFDM 系统的接收机部分，光电转换器（Photodetector，PD）接收到的信号 $y(t)$ 可表示为：

$$y(t) = x(t) * h(t) + n(t) \tag{2.10}$$

式中，* 为卷积运算符号。对时域接收信号 $y(t)$ 进行发射机上处理的反向处

理，即 A/D 信号转换，串行到并行转换以及去除 CP，快速傅里叶变换（Fast Fourier Transform，FFT）后可得到频域接收信号 **Y**，其表达式为：

$$\mathbf{Y}_{[m]} = \sum_{k=0}^{N-1} \mathbf{y}_{[k]} e^{\frac{-j2\pi km}{N}} \tag{2.11}$$

式中，$\mathbf{Y}_{[m]}$ 是频域接收信号 **Y** 的第 $m$ 个子载波符号，$\mathbf{y}_{[k]}$ 是时域接收信号 **y** 的第 $k$ 个子样本，其维度均为 $N \times 1$。将频域接收信号 **Y** 进行均衡以及星座图解码后，将并行的解码结果转换为串行的估计比特信息 $\hat{\mathbf{b}}$，即可完成一次传统 DCO-OFDM 信号传输。

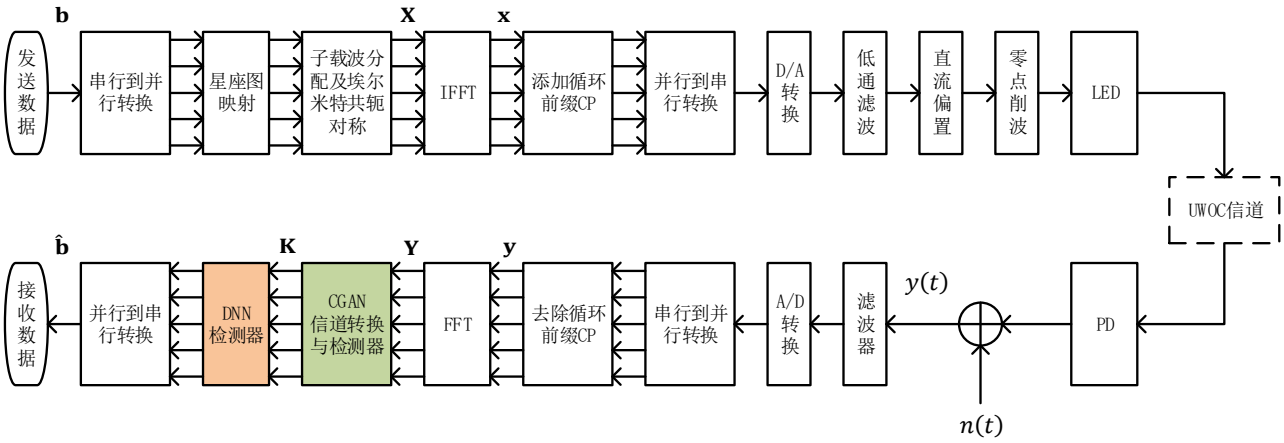


图 2-3 基于 DCO-OFDM 系统模型 SGD 实现流程框图

### 2.2.2 基于 DCO-OFDM 系统模型 SGD 实现流程

使用 DNN 检测器对接收的频域信号进行检测可实现比传统 DCO-OFDM 系统更精确的信号检测；然而，复杂且时变的 UWOC 信道会导致网络部署时当前信道与训练信道不同的情况，从而大大提高 DNN 检测器的误码率，影响通信质量，为了实现对于时变信道的跟踪以及当前信道与 DNN 检测器训练信道的匹配，可以使用 CGAN 信道转换与检测器实现当前信道与目标信道的转换具体而言，如图2-3所示，对于传统 DCO-OFDM 系统中 FFT 后得到的频域接收信号 **Y**，将该信号传入本设计中的 CGAN 信道转换与检测器中，并将信道特性转换后的信号 **K** 传入训练好的 DNN 检测器实现信号的检测，进行并行到串行的转换后即可得到发射比特信息 **b** 的估计结果 $\hat{\mathbf{b}}$，从而完成一次传统 DCO-OFDM 信号传输[26]。

## 2.3 SGD 线下训练以及线上更新流程

本节将详细介绍基于 CGAN-DNN 联合检测的 SGD 方案线下训练及线上更新的具体流程。

为了更形象地描述基于 CGAN-DNN 联合检测的 SGD 方案实现的功能，首先对该方案的部署环境进行假设如下：有 A，B，C 三片海域，其 UWOC 信道信号冲激响应分别为 $h_a$、$h_b$、$h_c$，我们将本 SGD 方案的实现流程分为以下三个阶段：数据集的产生，线下训练以及线上更新。

### 2.3.1 数据集的产生

在数据集的产生阶段，如图2-4所示，将随机生成的比特信息经过图2-3上半部分所示的发射机调制流程进行 DCO-OFDM 调制后，将发射信号通过 UWOC 信道 $h_a$、$h_b$ 以及 $h_c$，在接收端直接使用 PD 进行信号强度检测得到接收信号 $\mathbf{Y}_a$、$\mathbf{Y}_b$、$\mathbf{Y}_c$，训练数据集与测试数据集的生成采用相同的产生流程，但比特信息 **b** 随机生成；而 CGAN 训练集生成过程中，对于不同的信噪比（Signal Noise Ratio，SNR）参数，保证比特信息 **b** 不变从而可以训练 CGAN 的信道转换能力。具体而言，$\mathbf{Y}_a$、$\mathbf{Y}_b$、$\mathbf{Y}_c$ 在训练集上需要保证相同的比特信息 **b**，而在测试集以及中所有比特信息 **b** 应随机生成以验证系统的鲁棒性。

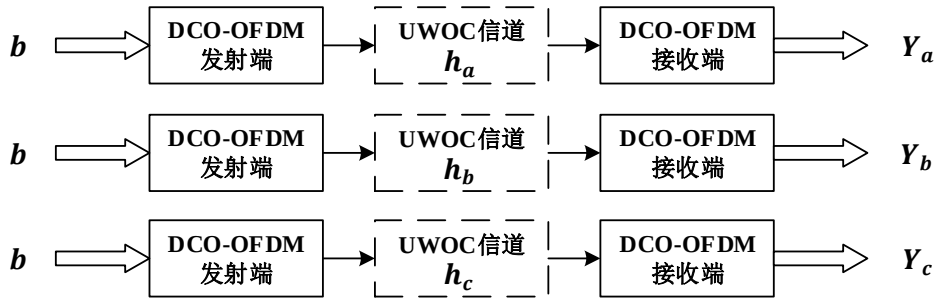


图 2-4 数据集产生流程框图

### 2.3.2 线下训练

线下训练阶段分为 DNN 的线下训练以及 CGAN 的线下训练，二者的关系如图2-5所示，而线下训练的具体目标则如图2-6、2-7以及图2-8所示。

如图2-6，DNN 检测器被训练于 $h_a$ 信道中，因此，线下训练结束后 DNN 检测器可实现 $h_a$ 信道接收信号的解调。为了使 DNN 检测器可以更精确地解调大部分

信号，应选取 UWOC 中较普遍的信道环境。如图2-7，CGAN 信道转换与检测器中的生成器被训练用于实现信道特征的转换，具体而言，该生成器的训练输入信号为发射比特通过 $h_b$ 信道的接收信号，而目标输出信号为发射比特通过 $h_a$ 信道的接收信号，其中噪声向量 **z** 为 CGAN 网络的噪声输入，不仅如此，经过线性组合后可用于抵消由于同一信道中随机的加性高斯白噪声 $n(t)$ 带来的不确定性。对于该训练，我们的目标是使 CGAN 可以实现具有 $h_b$ 信道特性的接收信号到具有 $h_a$ 信道特性的接收信号的转换，从而使转换后的结果可被 DNN 检测器准确识别。为了更好地训练 CGAN 的转换特征，$h_b$ 应采取与 $h_a$ 差别较大的信道。如图2-8，CGAN 信道转换与检测器中的判别器用于实现 CSI 变化的实时判别与追踪。具体而言，将发射比特通过 $h_a$ 信道的接收信号作为输入，则目标输出为 True，将发射比特通过 $h_b$ 信道的接收信号作为输入，则目标输出为 False，将发射比特通过 $h_a$ 信道的接收信号在生成器中输出的结果作为判别器的输入，则目标输出为 False，简而言之，判别器的目的是实现 CSI 变化的追踪，在经过与生成器的对抗训练后，判别器可判断接收信号是否为发射比特通过 $h_a$ 信道的接收信号。CGAN 结构总述如图2-9所示。$h_c$ 作为 CGAN 信道转换与检测器线上更新可行性的验证信道与误码率性能的对比信道，应采用随机生成的信道。

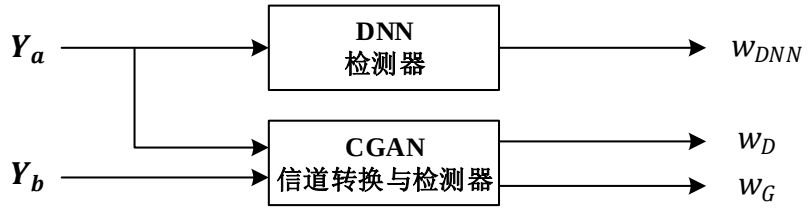


图 2-5 DNN 与 CGAN 线下训练关系图

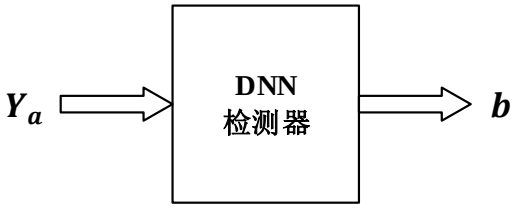


图 2-6 DNN 线下训练目标

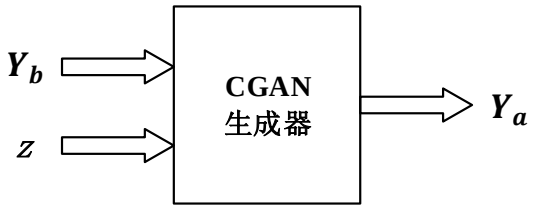


图 2-7 CGAN 生成器线下训练目标

图 2-8 CGAN 判别器线下训练目标

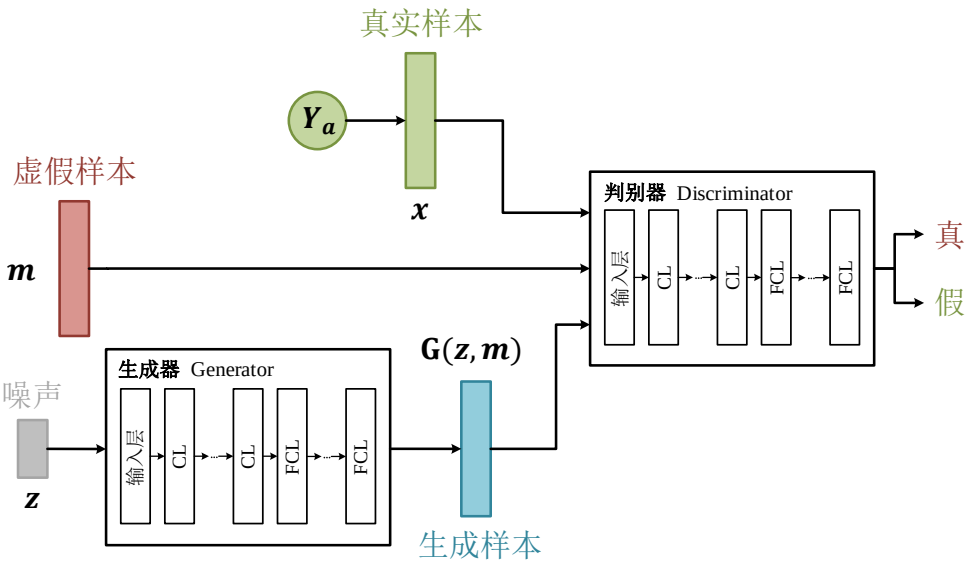


图 2-9 CGAN 结构总述

### 2.3.3 线上更新

在线上更新的阶段，只有 CGAN 信道转换与检测器中的生成器需要进行更新，但是否需要进行更新需要通过 CGAN 信道转换与检测器联合判别，其具体流程如图2-10所示。具体而言，假设该 SGD 方案被部署到 C 海域中，则该系统中 DCO-OFDM 接收到的是具有 $h_c$ 特性的导频信号，首先将接收导频输入 CGAN 信道转换与检测器中的判别器进行信道检测，其结果表示为 $D_1(\mathbf{Y})$，定义判决门限 $\rho_D = 0.5$，其中判别器的权重为2.3.2小节的线下训练权重 $w_D$，若 $\rho_D > 0.5$，则在误差允许范围内 $h_c = h_a$，此时 C 海域中信号接收结果 $\mathbf{Y}_c$ 可直接交由 DNN 检测器进行信号的恢复，若 $\rho_D < 0.5$，则 $h_c \neq h_a$，此时将导频接受结果 $\mathbf{Y}_p$ 输入权重为2.3.2小节中线下训练权重 $w_G$ 的 CGAN 生成器中得到信道特性转换后的信号 $G_{off}(\mathbf{Y}_p)$，将该信号输入 CGAN 信道转换与检测器中的判别器进行信道检测，其结果表示为 $D_2(\mathbf{Y})$，同样地，定义判决门限 $\rho_D = 0.5$，若 $\rho_D > 0.5$，则在误差允许范围内 $h_c = h_b$，此时 C 海域中信号接收结果 $\mathbf{Y}_c$ 可在经过线下训练的 CGAN 生成器得到 $G_{off}(\mathbf{Y}_c)$ 后交由 DNN 检测器进行信号的恢复，否则，$h_c \neq h_b \neq h_a$，此时仅依靠线下训练的神经网络无法对信号进行检测，需要进行 CGAN 信道转换与检测器中生成器的线上更新。

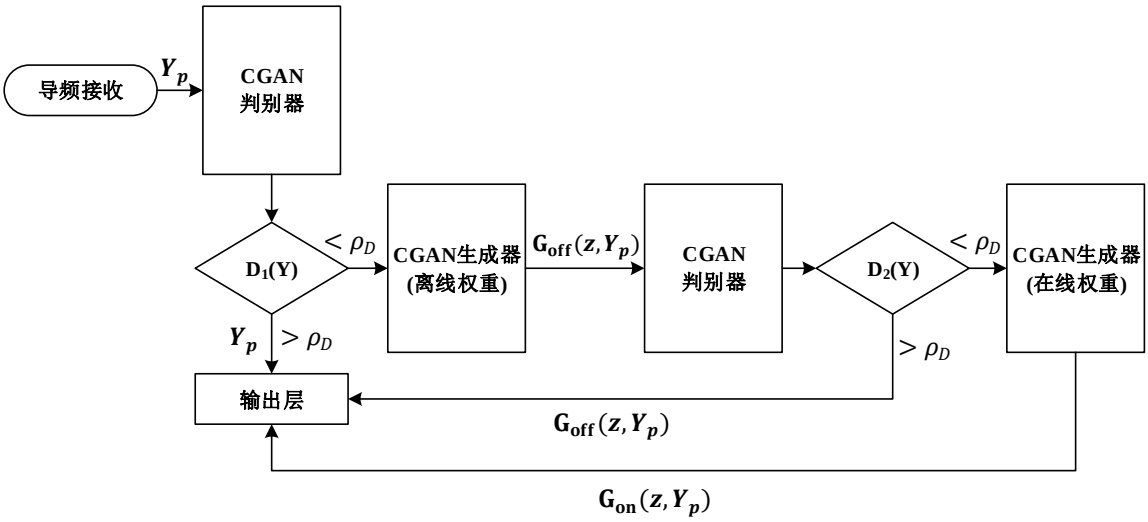


图 2-10 CGAN 信道转换器联合判别更新状态机制

线上更新的训练目标如图2-11所示。具体而言，生成器以信道 $h_c$ 的接收导频作为目标输入，以相同导频比特经过信道 $h_a$ 的接收结果作为目标输出以学习信道 $h_c$ 特征接受符号到信道 $h_a$ 特征接受符号的转换，进行线上更新后，可将信道 $h_c$ 的信号接收结果 $\mathbf{Y}_c$ 输入经过线上更新的 CGAN 生成器得到 $G_{on}(\mathbf{Y}_c)$ 后由 DNN 检

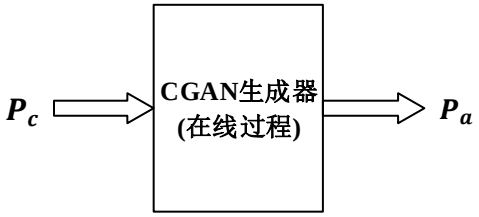


图 2-11 CGAN 生成器在线训练目标

测器进行信号的恢复。

## 2.4 DNN 检测器模型

本节将对设计中实现特定信道信号检测功能的 DNN 检测器进行介绍，包括 DNN 检测器的结构以及其训练方法。

### 2.4.1 DNN 检测器结构

本节将介绍用于训练信道 $h_a$ 的 DNN 检测器结构。由于 UWOC 信道具有时变性以及高度的复杂性，因此在本设计中，我们通过添加卷积层（Convolution Layer，CL）来实现更准确的特征提取，并且通过添加 Dropout 层避免对于训练数据的过度拟合，从而能在测试数据中有较好的表现。

如图2-12所示，DNN 网络由 CL 以及全连接层（Fully Connected Layer，FCL）组成，其中各项参数释义如下：

对于 CL，$F_c \times 1$ 代表第 $c$ 层 CL 的卷积核大小，$n = J_c$ 代表第层 CL 的卷积核数量为，$s = s_c$ 代表第 $N$ 层 CL 的卷积步长为 $s_c$。而对于 FCL，$N_l^F \times 1$ 代表第 $l$ 层 FCL 的神经元数量。其中，CL 共有 $C^S$ 层，FCL 共有 $L^S$ 层。

为了更方便地表示 DNN 的网络结构，可以用以下参数集：

$$S = \{C^S, \{F_1, ..., F_{C^S}, \{J_1, ..., J_{C^S}\}, \{s_1, ..., s_{C^S}\}; L^S, \{N_1^F, ..., N_{L^S}^F\}\}$$

对于 DNN，为了满足训练数据之间的非线性关系，层与层之间需要添加激活函数以避免各层输出数据之间的完全线性结果。在本设计中，对于 DNN 检测器中激活函数的选用，除了最后一层 FCL 外，我们在其余各层均采用了修正线性单元（Rectified Linear Unit，ReLU）作为激活函数。ReLU 函数因其非线性、计算简便性以及优良的梯度优化性质，在非线性拟合任务中可展现出卓越的性能[39]。对于最后一层 FCL，由于输出层的结果为二进制比特符号 0 或 1，我们选择了 Sigmoid 函数来将前一层的输出映射到（0，1）区间内。此时，映射结果可表示发射比特的估计概率，从而更准确地反映信号估计的状态。ReLU 函数以及 Sigmoid 函数图像如图2-13a、2-13b所示。

### 2.4.2 DNN 检测器训练

如2.2.2节所示，DNN 检测器的训练以发射比特符号 **b** 经过 UWOC 信道的接收结果作为输入，以真实发射的比特符号 **b** 作为训练输出，具体而言，该发射比特信息 **b** 通过图2-3中的发射机部分进行调制与滤波，并进入信道 $h_a$ 进行传输后

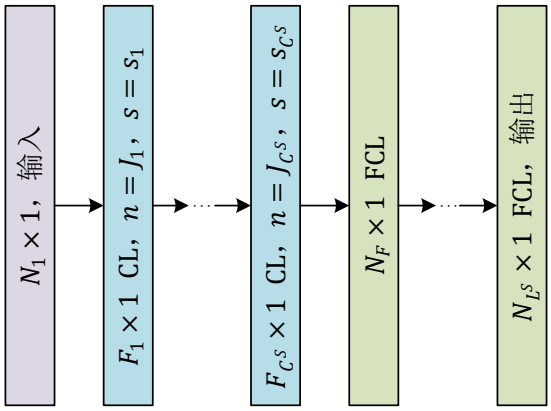


图 2-12 DNN 检测器结构

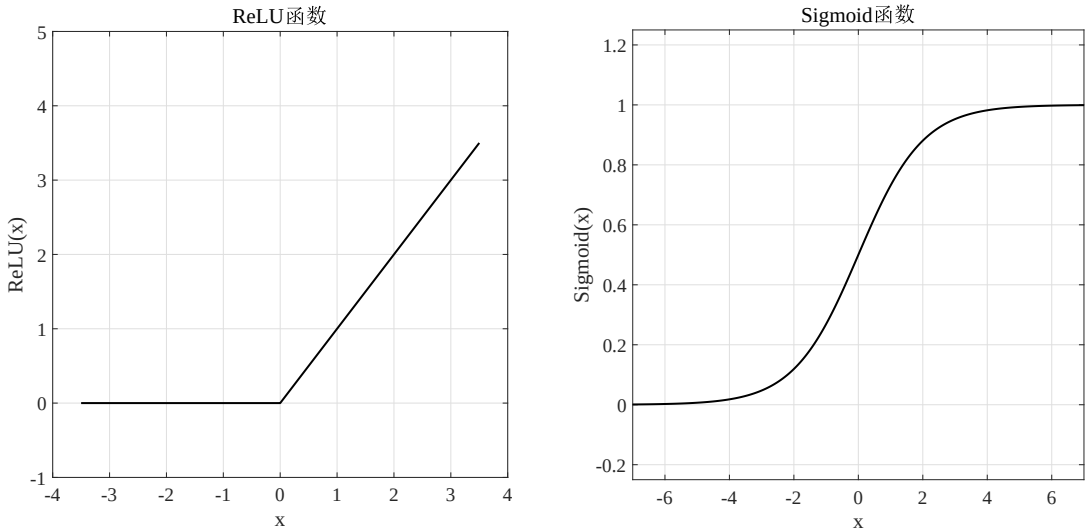


(a) ReLU 函数　　(b) Sigmoid 函数

图 2-13 激活函数图像

得到接收信号 $\mathbf{Y}_a$，经过训练后 DNN 检测器可以学习 $h_a$ 信道特征以及 OFDM 调制解调规律从而输出比特信息的估计序列 $\hat{\mathbf{b}}$。

为了最小化发射比特符号 $\mathbf{b}$ 以及估计序列 $\hat{\mathbf{b}}$ 的差距，从而实现精确解调，在 DNN 检测器的训练过程中采用均方误差（Mean Square Error，MSE）作为损失函数，在误差较小时加快收敛速度，其表达式如下：

$$loss = \mathbf{E}[(\mathbf{b} - \hat{\mathbf{b}})^2] \tag{2.12}$$

## 2.5 CGAN 信道转换与检测器模型

在 CGAN-DNN 联合检测的 SGD 方案中，CGAN 信道转换与检测器承担着信道特征转换以及信道变化跟踪的重要责任，是系统在时变 UWOC 信道中保持鲁棒

性不可或缺的组成部分。本节将从 CGAN 的原理、CGAN 的结构以及 CGAN 的训练三个方面详细介绍 CGAN 在联合检测 SGD 方案中的应用。

### 2.5.1 CGAN 原理介绍

为了更好地解释 CGAN，首先对其根基生成对抗网络（Generative Adversarial Net，GAN）进行介绍。2014 年，Ian Goodfellow 及其团队首次提出了 GAN 模型，该模型通过训练两个相互对抗的神经网络解决了非监督学习问题[40]，其中一个是生成（Generator，G）网络，另一个叫判别（Discriminator，D）网络。具体地说，GAN 网络的工作原理类似于一个警察与假钞制造者的博弈。生成器的目标是提取训练数据集的特征分布，并产生尽可能接近真实数据分布的假数据，而判别器的目标是区分自身的输入来自真实数据还是生成器产生的假数据。在训练过程中，生成器试图欺骗判别器，而判别器则努力提高其识别真伪的能力。当生成器准确学习了数据集的分布特征，同时判别器无法精确判断输入数据是否由生成器产生（此时判别概率为 0.5），训练过程达到收敛状态。这代表判别器已无法区分生成器产生的数据与真实数据，从而达到了良好的生成效果。相较于其他模型，GAN 的主要优势在于其训练过程不依赖于复杂的马尔可夫链或变分推断，而是可以直接通过反向传播技术进行有效学习。不仅如此，GAN 的架构提供了灵活性，允许采用多种网络结构和激活函数，使其能够针对特定应用需求进行个性化调整。

下面详细描述 GAN 的训练过程[40]，首先定义均匀分布噪声变量分布为 $p_z(\mathbf{z})$，真实数据样本分布为 $p_{data}(\mathbf{x})$，对于生成器，$G(\mathbf{z})$ 表示由上述分布输入噪声生成的虚假数据样本，对于判别器，我们使用 $D(\mathbf{a})$ 来表示数据样本 $\mathbf{a}$ 属于真实数据样本集而非由生成器产生的概率。模型对生成器生成数据样本分布 $G(\mathbf{z})$ 与真实数据样本分布 $p_{data}(\mathbf{x})$ 的差异函数 $V(G,D)$ 作出了定义：

$$V(G,D) = \mathbf{E}_{\mathbf{x}\sim p_{data}(\mathbf{x})}[\log D(\mathbf{x})] + \mathbf{E}_{\mathbf{z}\sim p_z(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))] \tag{2.13}$$

该式用于计算虚假数据样本 $G(\mathbf{z})$ 与真实数据样本 $p_{data}(\mathbf{x})$ 的差异。对于整一个对抗网络，为了使 $G(\mathbf{z})$ 尽可能接近 $p_{data}(\mathbf{x})$ 的分布，同时使 $D(\mathbf{a})$ 在判别门限二值化下更接近真实值，训练过程中判别器应调整网络参数使差异函数 $V(G,D)$ 最大化，即更好地区分样本来自真实数据和生成器的区别，而生成器则应该在最大化差异函数 $V(G,D)$ 的判别器参数下最小化差异函数 $V(G,D)$，即在上一次判别器训练结束后再次优化以尝试欺骗判别器。

具体地说，GAN 的训练过程分为以下四个步骤，图2-14中的四张子图对应了

以下的四个步骤：

1）初始化，首先随机初始化生成器 G 和判别器 D 的权重参数，以打破对称性并确保学习过程的开始。如图2-14a生成器 G 接收一个均匀分布噪声向量 $p_z(\mathbf{z})$ 作为输入，判别器 D 接收两种输入：绿色实心圆代表的真实数据样本分布 $p_{data}$ 以及蓝色实线代表的生成器生成样本分布 $p_G$，此时红色虚线代表判别器判别结果分布 $p_D$；

2）训练判别器，判别器的目标是正确分类输入样本，即区分真实数据样本和生成器产生的假数据样本。在训练判别器的阶段，从真实数据集 $p_{data}$ 中随机抽取一批样本，并同时从生成器生成一批假样本 $p_G$，判别器的权重参数 $w_D$ 通过最小化二元交叉熵损失函数（Binary Cross Entropy，BCE）进行更新，此时判别器逐渐可区分出真实数据样本与生成器生成样本的差别，如图2-14b所示；

3）训练生成器，生成器的目标是生成尽可能接近真实数据分布的样本，以欺骗判别器。在训练生成器的阶段，随机生成一批新的噪声向量 $p_z(\mathbf{z})$，并使用当前的生成器参数 $w_G$ 生成一批假样本 $p_G$。生成器的权重参数 $w_G$ 通过最大化判别器犯错的概率进行更新，即最大化 $\log(1-D(G(\mathbf{z})))$，此时生成器生成样本分布 $p_G$ 逐渐靠近数据样本分布 $p_{data}$，如图2-14c所示；

4）迭代过程，重复 2）、3）直至模型收敛，训练结束后判别器无法比随机样本更好地区分生成器生成样本与真实数据样本，如图2-14d，生成器生成数据样本分布 $p_G$ 与真实数据样本分布 $p_{data}$ 基本一致。

在深入理解了 GAN 的基本原理和训练方法之后,我们可以进一步探讨 CGAN[41]。CGAN 是在传统 GAN 框架的基础上发展而来，通过在生成器 G 和判别器 D 都引入一些外部条件信息 **m** 的方式，它能够生成与特定条件相符合的数据样本。这种网络结构不仅能够学习数据的分布，还能够根据给定的条件信息生成具有特定属性的样本，如类别标签或文本描述。与 GAN 中的 $V(G,D)$ 类似，生成器生成数据样本分布 $G(\mathbf{z})$ 与真实数据样本分布 $p_{data}(\mathbf{x})$ 的差异函数 $V_c(G,D)$ 为[41]：

$$V_C(G,D)=\mathbf{E}_{\mathbf{x}\sim p_{data}(\mathbf{x})}[\log D(\mathbf{x}\mid\mathbf{m})]+\mathbf{E}_{\mathbf{z}\sim p_z(\mathbf{z})}[\log(1-D(G(\mathbf{z}\mid\mathbf{m})))] \tag{2.14}$$

其相应的生成器和判别器目标函数与 GAN 类似。

CGAN 在多个领域展现出了巨大的应用潜力，例如在图像编辑中，可以根据用户指定的标签生成新的图像样本[42]。除了在计算机视觉中的应用外，在通信领域的信道表示和性能优化方面也有突出作用。2020 年，Ye 及其团队使用 CGAN 来模拟无线信道的影响，并将 CGAN 作为发射器和接收器 DNN 之间的桥梁，使得发

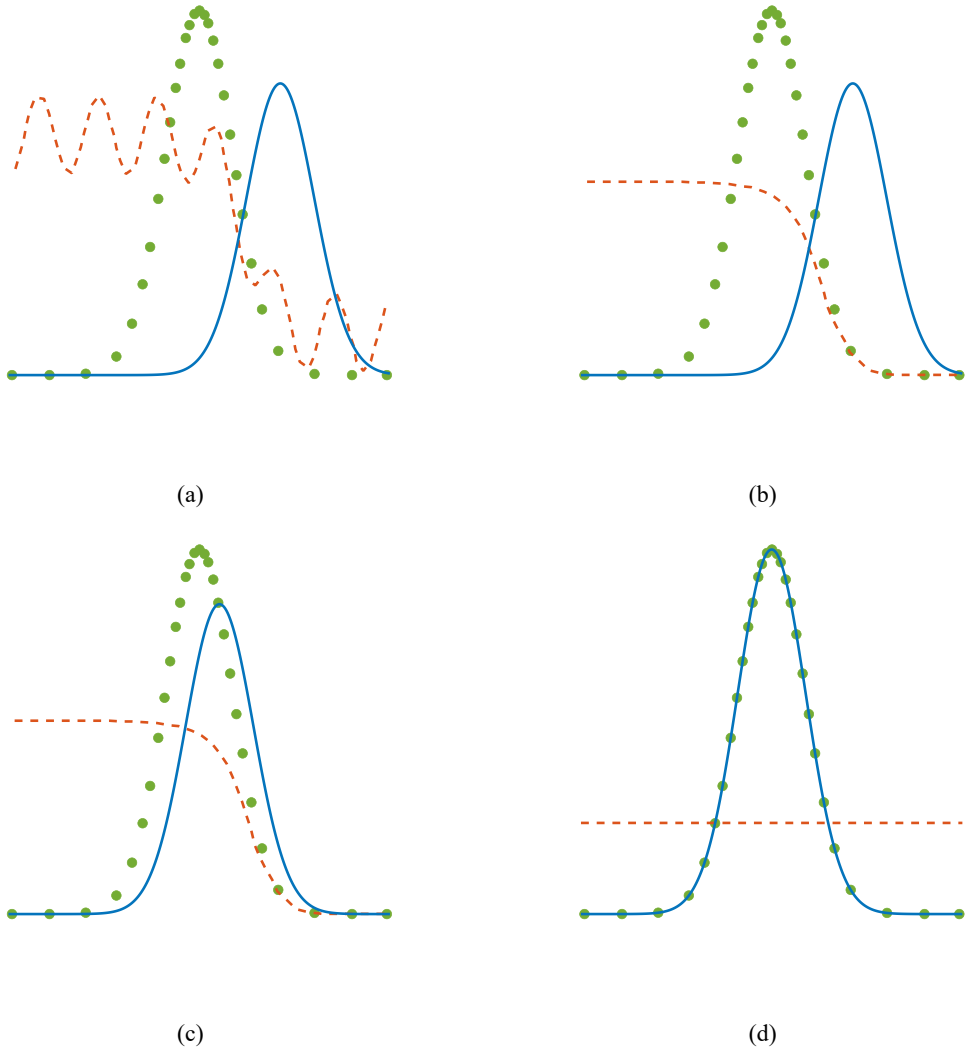


图 2-14 GAN 训练步骤结果图

射器 DNN 的梯度可以通过接收器 DNN 进行反向传播。这种方法允许系统在不需要精确估计 CSI 的情况下进行训练，从而实现端到端的网络结构[43]。2023 年，付重阳及其团队使用 CGAN 进行信号的降噪处理，通过将生成器拆分为编解码器实现了信号特征的提取，完成了高效的降噪[44]。

### 2.5.2 CGAN 信道转换与检测器结构

由2.5.1小节可知，CGAN 是一种对抗式的生成网络模型，该模型目标为：利用输入的条件信息 **m** 通过随机噪声 **z** 生成符合条件信息对应分布的样本 $p_{data}$。对于本设计，为了使 CGAN 信道转换与检测器实现信道特征的提取以及信号的信道特征转换，我们将条件信息 **m** 定义为符合当前信道特征的接收信号 $\mathbf{Y}_c$，即发射比特 **b** 通过 $h_c$ 信道的接收信号；而目标分布则为符合 DNN 检测器的训练信道特征的接收信号 $\mathbf{Y}_a$，即发射比特 **b** 通过 $h_a$ 信道的接收信号。

CGAN 信道转换与检测器设计中的生成器和判别器与2.4.1小节中所描述的 DNN 检测器在结构上相似，然而，在生成器的设计中，由于其目标输出为预测的目标信道特征信号，因此对其最后一个 FCL 采用了线性激活函数，从而避免了生成信号幅度受到的限制，其数学表达式为：

$$f_L(x) = x \tag{2.15}$$

在 DCO-OFDM 调制方法下，OOFDM 符号相邻子载波上的信道参数呈现出一定的空间相关性。因此，为了提取信号的信道特征，对于 CGAN 信道转换与检测器中的生成器，我们采用包含 CL 的网络结构提取当前信号的信道特征，以便在部署中完成信道特征的转换。此外，CL 结构也被应用于判别器中，使 CGAN 信道转换与检测器能高效地提取 CSI 特征，从而实现信号信道特征实时、准确的判别。

与2.4.1小节类似，包含 CL 的 CGAN 信道转换与检测器中，生成器与判别器的 DNN 网络结构可以用以下参数集表示：

$$S^G = \{C^G, \{F_1, ..., F_{C^G}, \{J_1, ..., J_{C^G}\}, \{s_1, ..., s_{C^G}\}; L^G, \{N_1^F, ..., N_{L^G}^F\}\}$$

$$S^D = \{C^D, \{F_1, ..., F_{C^D}, \{J_1, ..., J_{C^D}\}, \{s_1, ..., s_{C^D}\}; L^D, \{N_1^F, ..., N_{L^D}^F\}\}$$

其中，$(\cdot)^G$ 和 $(\cdot)^D$ 分别代表生成器和判别器的参数。CGAN 的结构如图2-9所示。此外，为了减小网络对超参数初始化的依赖，提高深度神经网络的泛化性，并提高网络学习率，我们在 CGAN 的 CL 层后添加了批归一化（Batch Normalization，BN）层[45]。

### 2.5.3 CGAN 信道与转换检测器训练

如2.5.2小节所示，在 CGAN 信道转换与检测器训练过程中，判别器和生成器通过交替训练的方式进行竞争优化。在训练过程中，判别器的目标是尽可能准确地判断输入样本是否属于真实样本集 $p_{data}$，而生成器则不断优化以生成与真实样本 $p_{data}$ 分布高度相似的样本，从而混淆判别器的判断。这一训练过程将持续进行，直至达到一个平衡点，即判别器在区分真实数据和生成的假样本时，其性能无法超过随机猜测的水平，此时我们定义判别概率为 0.5 作为阈值。一旦到达这一状态，训练过程将自动结束。

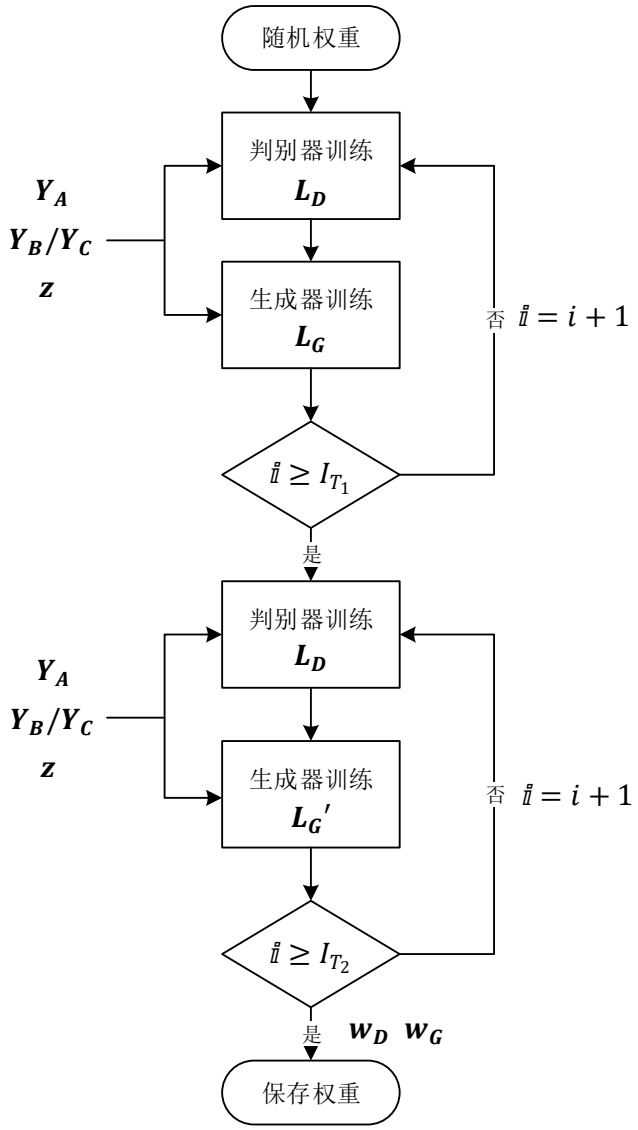


图 2-15 CGAN 训练流程图

对于传统的无监督 CGAN，生成器与判别器的优化目标函数可表示为：

$$L_G = \min_{w_G} \mathbf{E}_{\mathbf{z}\sim p_z}[\log(1 - D(G(\mathbf{z}, \mathbf{m}), \mathbf{m}))] \tag{2.16a}$$

$$L_D = \max_{w_D} \mathbf{E}_{\mathbf{x}\sim P_{data}}[\log(D(G(\mathbf{x}), \mathbf{m}))] + \mathbf{E}_{\mathbf{z}\sim P_{\mathbf{z}}}[\log(1 - D(G(\mathbf{z}, \mathbf{m}), \mathbf{m}))] \tag{2.16b}$$

式中，$\mathbf{x}$ 是服从目标分布 $p_{data}$ 的真实数据样本向量，而 $\mathbf{z}$ 是服从均匀分布 $p_z$ 的噪声样本向量，$w_G$ 是生成器的网络权重，$w_D$ 是判别器的网络权重。对于该式，生成器的目标为最小化其生成结果 $G(\mathbf{z}, \mathbf{m})$ 输入判别器后的判别结果与 1（即判别为真）的差距；而判别器的目标则为最大化 $G(\mathbf{x})$ 为输入的判别结果（即判别更接近真），并且最小化 $G(\mathbf{z}, \mathbf{m})$ 输入的判别结果（即判别更接近假）。

上述优化目标函数适用于传统无监督 CGAN，在本设计中，为了使生成器生成样本与输入样本符合相同比特信息 **b** 的不同信道接收特征分布，需要使用 MSE 进行生成器的监督学习，因此我们设计了一种适用于本设计 CGAN 信道转换与检测器的分段训练方案，将常规的无监督对抗训练作为前半段的训练目标，即最小化 $L_G$，而后半段的训练将信道转换中同一比特信息 **b** 经过两信道的接收结果作为训练转换目标，即使用 MSE 进行生成器的监督训练，最小化 $L_G$'。而判别器与传统无监督 CGAN 一样，以区分生成器生成样本与真实样本为目标，最大化 $L_D$。

训练流程如2-15所示，其中 $L_G$ 如式2.16a所示，$L_D$ 如式2.16b所示，$L_G$' 如下式所示：

$$L_G' = \min_{w_G} \mathbf{E}_{\mathbf{z}\sim p_z}[(G(\mathbf{z},\mathbf{m}) - \mathbf{x})^2] \tag{2.17}$$

对于线下训练与线上更新而言，CGAN 的训练流程并没有本质的区别，唯一的区别在于线下训练的 $I_T$ 大于线上更新，这是因为在联合检测的 SGD 设计中，线下训练时选择的信道 $h_a$、$h_b$ 特性差异较大，因此需要更多的迭代步数进行学习，然而在线上更新的过程中，$h_b$、$h_c$ 特性差异较小，因此迭代步数需求更小，这也符合实际部署中的要求：线下训练可以为了更精准而花费较多时间成本，而线上部署时需要实时检测，实时更新以实现高效率的通信。

# 第 3 章 系统改进方案

本章将对基于第2章中系统进行改进的 SGD 方案进行详细介绍。

## 3.1 改进的 SGD 方案线下训练以及线上更新流程

本节将详细介绍改进的 SGD 方案模块及其线下训练流程、线上更新运用。

本设计共对2.2.2小节所介绍的 SGD 方案进行了两点改进：

1）在使用 CGAN 信道转换与检测器与 DNN 检测器进行联合信号生成与检测的线上更新过程中，当 CGAN 的判别器检测到信道与自身训练信道有差异时，启动固定步数的线上更新步骤，然而，对于与训练信道相似度不一样的信道，CGAN 的线上更新收敛步数存在差别，使用固定步数的更新会导致无效训练的产生，从而提升了时间复杂度，造成了算力的浪费。为了解决该问题，本设计采用了 Siamese 线上更新控制器，对比当前信道接收信号与训练信道接收信号的相似度，根据相似度估计线上更新的训练收敛步数，从而节省了时间成本；

2）为了使用 CGAN 信道检测器实现信道转换，需要使用大量配对样本对 CGAN 网络进行监督训练，从而使 CGAN 网络精确学习信道特征，提高转换的准确率，然而，在 UWOC 系统中，采集大量训练信号样本需要高昂的成本，在实际应用中，为了降低采集数据所需要的成本，本设计使用循环一致性生成对抗网络（Cycle-Consistent Generative Adversarial Net，CycleGAN）对 CGAN 进行了替换，只需用少量训配对练样本对 CycleGAN 进行适应性训练，接着执行无监督训练进行信道特征的提取与转换直至收敛即可完成网络权重的定型，大大降低了训练样本数据的需求，从而减少了采集样本所需的开销。

同样地，为了更好地介绍本 SGD 改进方案实现的流程以及功能，在2.3节的基础上，我们定义 D、E、F 三片海域用于 Siamese 网络的训练与测试，其 UWOC 信道信号冲激响应分别为 $h_d$、$h_e$、$h_f$，接下来将从数据集的产生，线下训练以及线上更新三个方面对改进的 SGD 方案进行补充介绍。

### 3.1.1 数据集的产生

对于上述三个信道的数据集生成方式与2.3.1小节相同，将随机生成的比特信息 **b** 经过图2-3上半部分所示的发射机调制流程进行 DCO-OFDM 调制后，将发射

信号通过 UWOC 信道 $h_d$、$h_e$ 以及 $h_f$，在接收端直接使用 PD 进行信号强度检测得到接收信号 $\mathbf{Y}_d$、$\mathbf{Y}_e$、$\mathbf{Y}_f$（统称为 $\mathbf{Y}_m$）。对于上述接收信号的产生过程，训练集使用的发射信号 **b** 应为随机比特。为了进行误码率性能的计算与验证，测试集中需要有相同发射比特 **b** 通过信道 $h_a$ 的接收信号 $\mathbf{Y}_a$。

### 3.1.2 线下训练

Siamese 网络的线下训练目标如图3-1所示，$h_d$、$h_e$ 为 Siamese 网络的训练信道，$h_f$ 为测试信道。Siamese 网络被用于度量当前接收信号信道特征与 CGAN 训练信道 $h_b$ 信道特征的区别，并预测建议采用的线上更新步数。具体而言，首先将多个不同时刻的训练或测试信道接收信号 $\mathbf{Y}_m$、$\mathbf{Y}_b$ 输入交织器中，交织器随机选取 $\mathbf{Y}_b$ 内部两个时刻的接收信号作为正样本对，接着随机选取 $\mathbf{Y}_m$、$\mathbf{Y}_b$ 任一时刻的接收信号作为负样本对，将 $\mathbf{Y}_m$ 通过 CGAN 线上更新收敛所需的最小步骤作为输出结果 $e$ 的训练目标，最终实现线上更新步数的控制。

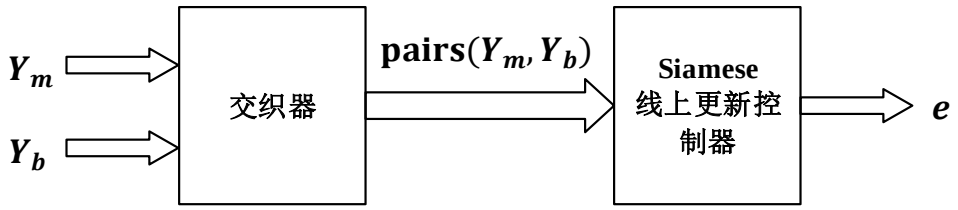


图 3-1 Siamese 线上更新控制器训练目标

对于 CycleGAN 信道转换与检测器的训练过程，作为 CGAN 的替换，其训练目标与 CGAN 相同，均为使网络可以实现具有 $h_b$ 信道特性的接收信号到具有 $h_a$ 信道特性的接收信号的转换，从而使转换后的结果可被 DNN 检测器准确识别，因此在 SGD 的实现流程中通过简单地将 CGAN 网络更换为 CycleGAN 网络即可进行方案的仿真与测试。

### 3.1.3 线上更新

Siamese 网络辅助的 SGD 实现流程框图如图3-2所示，Siamese 线上更新控制器与 CGAN 信道转换与检测器并联，FFT 后的频域接收信号 **Y** 同时输入 Siamese 网络与 CGAN 网络，Siamese 线上更新控制器的预测收敛步数 $e$ 指导 CGAN 信道转换与检测器完成线上更新。具体地说，如图3-3所示，在线上更新前，调用 Siamese 线上更新控制器对当前接收信号特征与 CGAN 信道转换与检测器训练信道特征进

行差异度量并输出更新步数，其权重为3.1.2小节所得到的 Siamese 网络线下训练权重 $w_S$。

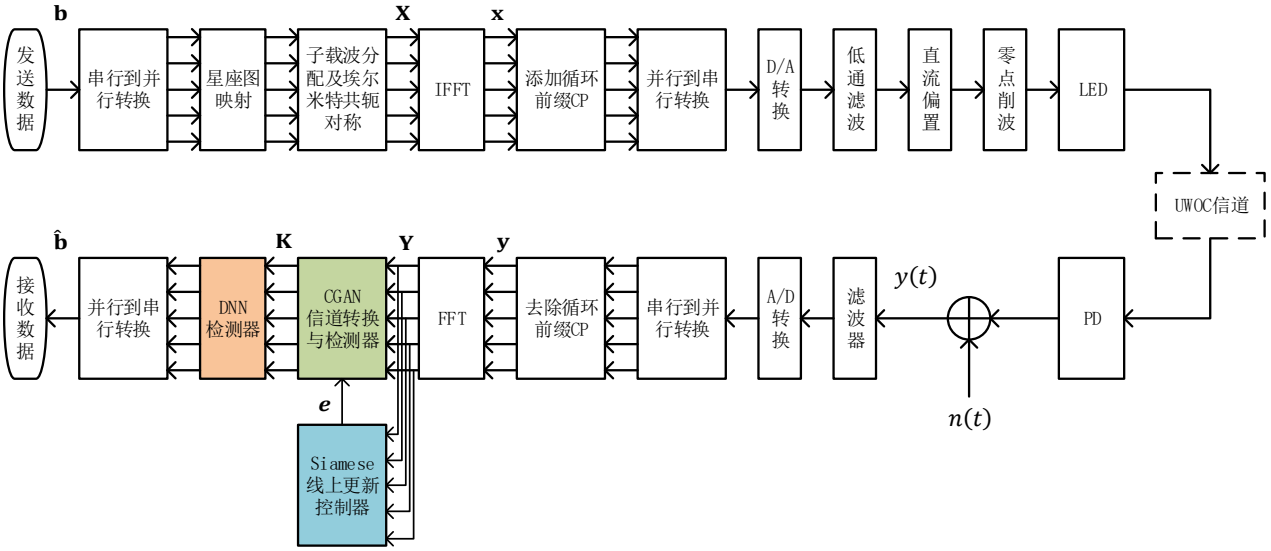


图 3-2 Siamese 线上更新控制器辅助的 SGD 实现流程框图

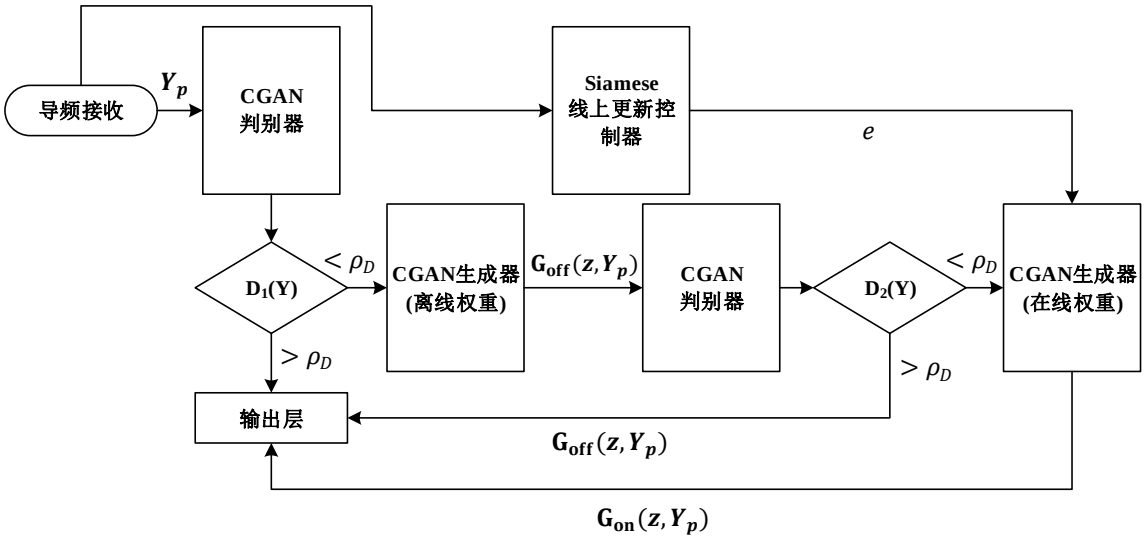


图 3-3 基于 Siamese 的 CGAN 信道转换器联合判别更新状态机制

## 3.2 Siamese 线上更新控制器模型

为了实现 CGAN 信道转换器线上更新步数的控制，本 SGD 方案提出了一种基于 Siamese 网络的线上更新控制器模型实时控制 CGAN 信道转换器的线上更新

过程。本节将从 Siamese 线上更新控制器原理、结构以及训练方法三个方面进行详细介绍。

### 3.2.1 Siamese 网络原理

在传统的机器学习和模式识别任务中，分类器通常被设计来识别单个输入样本属于预定义类别中的哪一个，如 CGAN 信道转换检测器的判别器。然而，在某些情况下，我们可能需要比较两个样本之间的相似性，而不是单独对每个样本进行分类。为了解决需要比较两个输入样本之间相似性的任务，尤其是在类别数量非常大或者在训练时无法获得所有类别样本的情况下，Chopra 及其团队提出了一种特殊的神经网络架构：Siamese 网络[46]，该网络被用于学习输入数据之间的相似性度量。它的核心思想是使用一个共享权重的双分支网络结构，这两个分支分别处理两个不同的输入样本，并输出对应的特征表示。通过这种方式，Siamese 网络能够比较两个输入样本的相似性，而不是像传统的分类任务那样对单个输入进行分类。Siamese 网络的工作原理有以下几个关键点：

1）输入。Siamese 网络接受一对样本作为输入，这两个输入样本可能属于同一个类别（正样本对），也可能属于不同的类别（负样本对）；

2）共享权重的双分支结构。这对输入样本分别通过两个结构相同且权重共享的子网络。这意味着两个子网络对输入样本的处理方式是一致的，从而确保了特征提取的一致性和对称性；

3）特征映射。每个子网络将输入样本映射到一个低维的特征空间中。这个映射旨在提取输入样本的特征，并使得相似的样本在特征空间中距离较近，而不相似的样本距离较远；

4）距离计算。两个子网络的输出是两个特征向量，它们之间的距离（例如欧几里得距离）或相似度（通过某种相似性度量计算）被用来评估输入样本之间的相似性；

5）损失函数。Siamese 网络的训练目标是最小化一个特定的损失函数，这个损失函数鼓励网络对于真实对产生小的相似性度量，而对于仿冒对产生大的相似性度量。这通常通过对比损失来实现，对比损失会根据两个输入样本是否属于同一类别来调整网络的权重。

对比于传统的深度学习分类方案，Siamese 网络主要有以下优势：

1）类别未知的情况。Siamese 网络不需要在训练时知道所有的类别，这使得它适用于类别数量大或未知的场景，UWOC 信道复杂且多变，在部署前无法获得所有可能信道的冲激响应，因此 SGD 方案中采用 Siamese 网络可有效避免由于实

际信道未知而导致的系统鲁棒性下降；

2）少量样本学习。Siamese 网络可以在每个类别只有少量样本的情况下进行有效的学习。对于本 SGD 方案，少量样本的学习可以大大降低训练中的时间复杂度，从而在稳定误码率的前提下降低时间成本；

3）对比学习。Siamese 网络通过比较两个输入样本来学习特征表示，这有助于模型捕捉样本之间的细微差异，而在通信中，CSI 的微小变化也可能会导致误码率的提升，因此准确判断线上更新的收敛步数对于降低系统误码率以及提升通信效率都至关重要。

目前，对 Siamese 网络的应用大多集中在图像以及视频的识别上，如：大规模人脸识别[47]，实时目标跟踪[48] 等等。

### 3.2.2 Siamese 线上更新控制器结构设计

Siamese 线上更新控制器在本 SGD 设计中的结构总述如图3-4所示

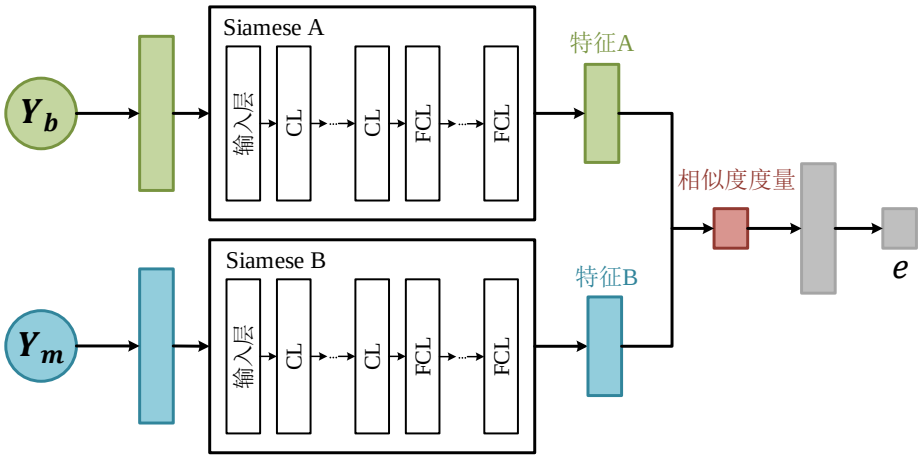


图 3-4 Siamese 结构

本方案中，为了实现值为 0→1 的相似度度量预测，在对特征向量进行相减后采用 Sigmoid 函数进行激活，Sigmoid 函数的图像如图2-13b所示；而对于 Siamese 网络的最后一层，为了避免输出幅度受限从而影响预测收敛步数的精度，采用线性函数对作为该层的激活函数，其表达式如式2.15所示。在前半部分的孪生特征提取网络中，为了实现接收信号的特征提取与比较，上下部分采用了相同的结构参数，该参数与 CGAN 信道转换与检测器中的判别器结构相似，可用以下参数集表

示：

$$S^J = \{C^J, \{F_1, ..., F_C, \{J_1, ..., J_C\}, \{s_1, ..., s_C\}; L^J, \{N_1^F, ..., N_{L^J}^F\}\}$$

其中 $(\cdot)^J$ 代表 Siamese 网络的参数。

### 3.2.3 Siamese 线上更新控制器训练

如3.1.2小节所示，Siamese 线上更新控制器通过提取信号的信道特征进行比对，从而得到接收信号信道特征与 CGAN 信道转换与检测器线下训练信号信道特征的相似度，根据该相似度数值指导 CGAN 信道转换与检测器的线上更新流程。

由图3-1所示，Siamese 线上更新控制器的训练以 **b** 经过 UWOC 信道的接收结果 $\mathbf{Y}_m$、$\mathbf{Y}_b$ 作为输入，经过交织器生成正负样本对后以该信道接收信号在 CGAN 信道转换与检测器线上更新完成收敛的步数 $e$ 作为输出。经过训练后 Siamese 线上更新控制器可通过当前接收信号判断需要对该信道进行多少步的训练从而使 CGAN 信道转换与检测器线上更新收敛，在不降低误码率性能的前提下降低线上更新步骤的时间复杂度。

在传统的 Siamese 网络中，损失函数指导网络学习如何区分相似的和不相似的样本对。针对 Siamese 网络的相似性判别问题，最常用的损失函数是对比损失函数，其定义如下：

$$L(W, \mathbf{x}_1, \mathbf{x}_2, y) = \frac{1}{2} y \cdot D^2(W, \mathbf{x}_1, \mathbf{x}_2) + \frac{1}{2}(1-y) \cdot \max(0, m - D(W, \mathbf{x}_1, \mathbf{x}_2))^2 \quad (3.1)$$

其中，$L$ 是损失函数，$W$ 是网络的参数，$x_1$，$x_2$ 是输入样本对，$y$ 是标签，如果两个样本是相似的，则 $y=0$，否则 $y=1$，$D(W, x_1, x_2)$ 是两个样本在网络中的嵌入表示之差的范数，而 $m$ 是一个边际值，用于控制正负样本对之间的边界。

而在本 SGD 设计中，由于网络最终要输出预估收敛步数 $e$，因此 Siamese 线上更新控制器在基础的 Siamese 网络添加了从相似度度量到更新步数的两层全连接层，同时，针对本改动，本设计提出了一种分段训练方法，在训练的前半段，以传统的对比损失函数3.1作为损失函数训练样本信道特征提取能力，在后半段以 MSE 作为损失函数训练样本差异与收敛步数的映射能力，其中，MSE 函数如下式所示：

$$loss = \mathbf{E}[(e - \hat{e})^2] \quad (3.2)$$

同样地，为了提高深度神经网络的泛化性以及网络学习效率，我们在 Siamese 网络的 CL 层后添加了 BN 层[45]。

## 3.3 CycleGAN 信道转换与检测器

上述 SGD 方案实现了在训练样本充足的情况下对于 UWOC 时变信道的信号恢复与检测，然而对于方案中的 CGAN 信道转换与检测器，若训练样本数量减少，其信道转换能力与检测能力将大大降低。为了完成在少量训练样本条件下的信道转换与检测，我们将 CycleGAN 引入了本设计中，并将 CGAN 中的条件部分也作为 CycleGAN 的输入进行训练，从而实现 SGD 方案在训练样本缺失的条件下的信道转换与检测能力。本节将主要从 CycleGAN 信道转换与判别器的原理、结构以及网络训练三个方面进行详细介绍。

### 3.3.1 CycleGAN 信道转换与检测器原理

在图像风格迁移的问题中，传统的转换模型，如 GAN、DNN 等，需要在训练时获取大量的配对样本，从而对网络进行有监督的训练，然而，在大部分时候我们无法获取成对的训练数据（即同一场景或对象在不同风格下的图像），例如，假设我们想要将普通马的图片转换为斑马的图片，在现实中，我们很难找到同一匹马在两种不同外观（普通马和斑马）下的照片，相反地，大部分情况下我们只有两个独立的图片集合：一个只包含普通马图片的集合以及一个只包含斑马图片的集合，此时无法使用传统的配对样本学习方案进行网络的训练。为了解决此类问题，2017 年，Zhu 及其团队在传统 GAN 网络上提出了 CycleGAN 网络[49]。CycleGAN 是一种无监督的图像到图像转换网络，它能够在没有成对训练样本的情况下，学习两个不同域（例如，照片和画作）之间的映射关系。其由两个生成器和一个判别器组成，每个生成器负责一个方向的样本转换，而判别器则用于区分真实样本和生成的样本。

CycleGAN 的核心创新在于其采用了循环一致性损失函数，该损失函数旨在确保在两个不同样本域之间的转换是可逆的。具体而言，给定一个源域 $X$ 和一个目标域 $Y$，CycleGAN 通过两个映射函数 $G: X \to Y$ 和 $F: Y \to X$ 来实现域之间的转换。循环一致性损失强制要求对于任意 $x \in X$，经过两次转换后应能恢复原始样本，即 $F(G(x)) \approx x$，同理对于 $y \in Y$，也有 $G(F(y)) \approx y$。这种循环一致性确保了在缺乏成对训练样本的情况下，学习到的映射能够保持样本的语义内容，从而实现了无监督的样本到样本转换。此外，CycleGAN 还结合了对抗性损失，以确保生成的样本在视觉上与目标域中的真实样本无法区分。通过这种方式，CycleGAN 能够在不需要成对数据的情况下，学习复杂的跨域样本转换函数。

下面具体介绍 CycleGAN 的训练方法及其损失函数[49]：

1）初始化，首先采用随机权重对生成器 $G: X \rightarrow Y$、$F: Y \rightarrow X$ 以及判别器 $D_Y$、$D_X$ 进行赋值，其在网络中的位置如图3-5所示，其中，$X$、$Y$ 分别代表待转换的源域以及目标域，通过随机初始化打破平衡，开始训练过程；

2）训练判别器，从 $X$、$Y$ 中分别采样一批样本 $x$、$y$，使用生成器 $G$ 将源域样本 $x$ 转换为虚假目标域样本 $G(x)$，同时使用生成器 $F$ 将目标域样本 $y$ 转换为虚假源域样本 $F(y)$，得到虚假样本后，根据式3.3更新判别器 $D_Y$ 以及 $D_X$ 的参数，以最大化对抗损失；

$$L_{D_Y} = \max_{w_{D_Y}} \mathbf{E}_{y \sim p_{data}(y)}[\log D_Y(y)] + \mathbf{E}_{x \sim p_{data}(x)}[\log(1 - D_Y(G(x)))] \tag{3.3a}$$

$$L_{D_X} = \max_{w_{D_X}} \mathbf{E}_{x \sim p_{data}(x)}[\log D_X(x)] + \mathbf{E}_{y \sim p_{data}(y)}[\log(1 - D_X(F(y)))] \tag{3.3b}$$

其中，$w_{D_Y}$ 与 $w_{D_X}$ 为判别器 $D_Y$、$D_X$ 的权重参数。

3）训练生成器，同样地，从 $X$、$Y$ 中分别采样一批样本 $x$、$y$，使用生成器 $G$ 将源域样本 $x$ 转换为虚假目标域样本 $G(x)$，并将其通过生成器 $F$ 转换为虚假源域样本 $F(G(x))$；使用生成器 $F$ 将目标域样本 $y$ 转换为虚假源域样本 $F(y)$，并将其通过生成器 $G$ 转换为虚假目标域样本 $G(F(y))$，对于以上生成样本，根据式3.4更新生成器 $G$ 和 $F$ 的网络权重参数，以最小化总损失函数：

$$L_{G,F} = L_G + L_F + \lambda_{cyc} L_{cyc} \tag{3.4}$$

其中，$\lambda_{cyc}$ 为循环一致性损失的权重参数，生成器 $G$ 的损失函数 $L_G$、生成器 $F$ 的损失函数 $L_F$、循环一致性损失函数 $L_{cyc}$ 的表达式如式3.5所示：

$$L_G = \min_{w_G} \mathbf{E}_{\mathbf{y} \sim p_{\text{data}}(\mathbf{y})}[\log D_Y(\mathbf{y})] + \mathbf{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})}[\log(1 - D_Y(G(\mathbf{x}))] \tag{3.5a}$$

$$L_F = \min_{w_F} \mathbf{E}_{\mathbf{y} \sim p_{data}(\mathbf{y})}[\log(1 - D_X(F(\mathbf{y})))] + \mathbf{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})}[\log(D_X(\mathbf{x}))] \tag{3.5b}$$

$$L_{\text{cyc}} = \min_{w_G, w_F} \mathbf{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})}[\|F(G(\mathbf{x})) - \mathbf{x}\|_1] + \mathbf{E}_{\mathbf{y} \sim p_{\text{data}}(\mathbf{y})}[\|G(F(\mathbf{y})) - \mathbf{y}\|_1] \tag{3.5c}$$

其中，$w_G$ 与 $w_F$ 为生成器 $G$、$F$ 的权重参数。

4）重复执行步骤 2）和 3），直至模型收敛，此时模型可以实现对 $X$ 域输入样本的 $Y$ 域特征转换，且训练过程中无需配对样本。

近年来，CycleGAN 以其无需配对样本的优势在除了图像以外的许多领域得到了应用。在非并行语音转换任务中，CycleGAN 可以在没有源说话者和目标说话者之间对应语音数据的情况下，将源说话者的声音转换为目标说话者的声音，同时不

改变语音的语言信息[50]。而在通信领域中，CycleGAN 同样有着突出的作用。2022 年，赵志民在对空间涡旋光通信系统的研究中，使用改进损失函数的 CycleGAN 对空间涡旋光畸变进行了补偿，从而在节省光学器件的条件下保持了优秀的补偿性能[51]。同年，文献[52] 提出了将通信中的信号矩阵作为图像的思路，使用 CycleGAN 实现了信号高信噪比“特征”与低信噪比“特征”的转换，提高了调制识别的准确率。

### 3.3.2 CycleGAN 信道转换与检测器结构

由3.3.1小节可知，CycleGAN 可以在无需配对数据的情况下实现源域 $X$ 到目标域 $Y$ 的样本风格相互转换，而文献[52] 带来了将信号作为图像应用于 CycleGAN 中的思路。在本设计中，为了使 CycleGAN 实现相同比特信息 **b** 通过目标信道 $h_b$ 与实际信道 $h_c$ 产生信号之间的相互转换，我们定义 CycleGAN 中源域 $X$ 为符合实际信道 $h_c$ 特征的接收信号集合，目标域 $Y$ 为符合目标信道 $h_b$ 特征的接收信号集合，在本 SGD 方案中使用 CycleGAN 替换 CGAN 实现信道转换与检测的理由如下:

1）如3.3.1小节所述，CycleGAN 无需要成对的训练数据，这意味着它可以学习两个不同域之间的映射，而不需要每个源域样本都有一个对应的目标域样本。在复杂的深海通信系统中，获取训练样本的成本极高，使用 CGAN 进行训练样本的完整采集将耗费巨额的人力和物力资源。相比之下，采用 CycleGAN 执行信道转换与检测的任务能够显著降低成本的支出；

2）CycleGAN 通过引入循环一致性损失，确保转换前后的样本在语义上保持一致。这种方法有助于保持原始样本的语义内容。在本 SGD 设计中，使用 CycleGAN 进行信道转换可以更好地保证转换前后接收信号是由相同的发射比特信息 **b** 通过不同信道接收的结果，在无监督训练的条件下保持接收信号携带信息的不变性；

3）CycleGAN 可以适应新的数据集和任务，只需对网络进行适当的调整和训练。因此 CycleGAN 同样可以通过线上更新方法适应 UWOC 中的时变 CSI，完成对信道变化的跟踪以及适应式更新，维持系统的鲁棒性。

本 SGD 设计中，为了使 CycleGAN 更好地提取信号的信道特征，我们采用与2.5节相同的结构参数进行网络的搭建，其结构可以用以下表达式表示：

$$S^{G'} = \{C^{G'}, \{F_1, ..., F_{C^{G'}}, \{J_1, ..., J_{C^{G'}}\}, \{s_1, ..., s_{C^{G'}}\}; L^{G'}, \{N_1^F, ..., N_{L^{G'}}^F\}\}$$

$$S^{F'} = \{C^{F'}, \{F_1, ..., F_{C^{F'}}, \{J_1, ..., J_{C^{F'}}\}, \{s_1, ..., s_{C^{F'}}\}; L^{F'}, \{N_1^F, ..., N_{L^{F'}}^F\}\}$$

$$S^{D_X} = \{C^{D_X}, \{F_1, ..., F_{C^{D_X}}, \{J_1, ..., J_{C^{D_X}}\}, \{s_1, ..., s_{C^{D_X}}\}; L^{D_X}, \{N_1^F, ..., N_{L^{D_X}}^F\}\}$$

$$S^{D_Y} = \{C^{D_Y}, \{F_1, ..., F_{C^{D_Y}}, \{J_1, ..., J_{C^{D_Y}}\}, \{s_1, ..., s_{C^{D_Y}}\}; L^{D_Y}, \{N_1^F, ..., N_{L^{D_Y}}^F\}\}$$

其中 $(\cdot)^{G'}$、$(\cdot)^{F'}$、$(\cdot)^{D_X}$、$(\cdot)^{D_Y}$ 分别代表 CycleGAN 中生成器 $G$、$F$ 以及判别器 $D_X$、$D_Y$ 的网络结构参数。

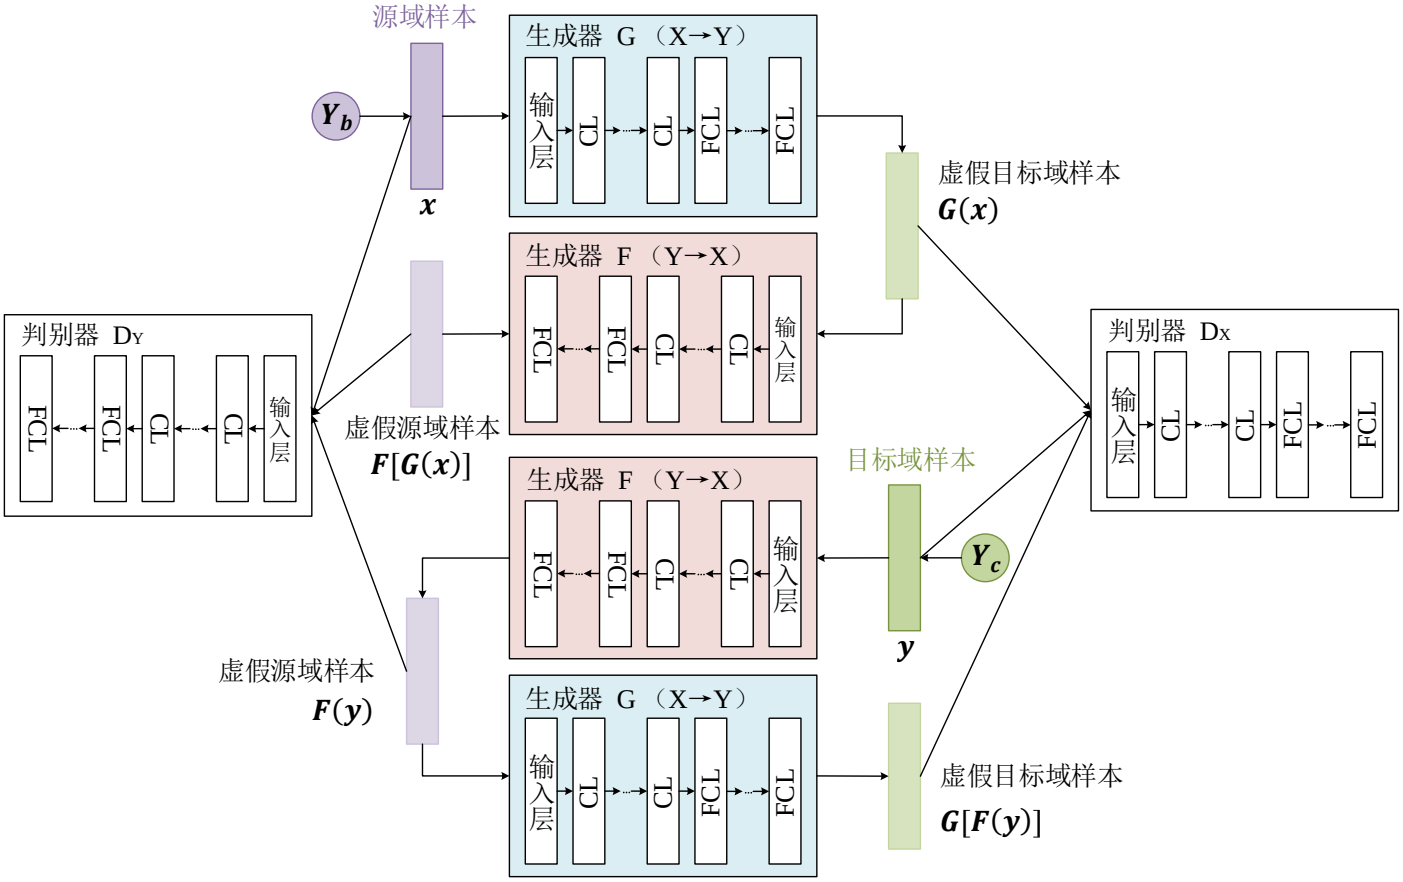


图 3-5 CycleGAN 结构

### 3.3.3 CycleGAN 信道转换与检测器训练

如3.1.2小节所示，与 CGAN 信道转换与检测器相似，CycleGAN 通过接收当前信道的信号作为输入并输出具有 DNN 检测器训练信道特性的信号，从而使 DNN 检测器工作在训练信道环境下，提升误码率性能。对于 CycleGAN 信道转换与检测器，为了保证该网络能够更充分迅速地识别接收信号 **Y** 与发射比特符号 **b** 的语义对应关系，首先使用较少量的配对数据对生成器 $G$、$F$ 进行适应性有监督训练，接着再使用无配对的样本对模型中的生成器 $G$、$F$ 以及判别器 $D_X$、$D_Y$ 进行无监督训练，从而使模型完成收敛。适应性训练的损失函数如式3.6所示，而无监督训

练的损失函数如式3.5所示。

$$L'_G = \min_{w_G} \mathbf{E}_{\mathbf{y}\sim p_{\text{data}}(\mathbf{y}),\mathbf{x}\sim p_{\text{data}}(\mathbf{x})}[\mathbf{y} - G(\mathbf{x})]^2 \tag{3.6a}$$

$$L'_F = \min_{w_F} \mathbf{E}_{\mathbf{x}\sim p_{\text{data}}(\mathbf{x}),\mathbf{y}\sim p_{\text{data}}(\mathbf{y})}[\mathbf{x} - F(\mathbf{y})]^2 \tag{3.6b}$$

其中，$w_G$ 与 $w_F$ 为生成器 $G$、$F$ 的权重参数。具体地说，在适应性训练阶段，为了避免网络参数陷入局部最优解，首先对 CycleGAN 信道转换与检测器进行基于少量配对数据的有监督训练，以最小化生成器结果与真实样本作为训练目标，从而训练网络的比特符号特征提取能力，接着，仅使用 CycleGAN 训练信道接收信号 $\mathbf{Y}_c$ 进行无监督训练，通过最小化 $L_G, F$，使网络参数完成收敛，从而实现信道转换与判别的功能。

# 第 4 章 仿真验证与测试

本章将通过仿真对联合检测 SGD 方案中的 DNN 检测器、CGAN 信道转换与检测器线下训练以及线上更新的性能以及 CycleGAN 信道转换与检测器替换方案进行了测试，并将其与传统方案，如 LS 和 LMMSE 信道估计方法[53] 的性能进行了比较，从而展示了设计方案的误码率性能优越性。不仅如此，本章还对基于 Siamese 线上更新控制器的受控 SGD 方案与无 Siamese 线上更新控制器的 SGD 方案性能以及效率进行了对比，从而体现 Siamese 网络在降低时间复杂度上的贡献。

## 4.1 仿真设置

本 SGD 方案基于 UWOC 信道实现，因此我们采用基于蒙特卡洛方法[33] 的 DCO-OFDM 调制[37] 实现对 UWOC 信道的仿真。在仿真过程中，我们设定了一个收发机之间相对位移的通信场景，用以模拟 CSI 的动态变化。具体而言，发射机被固定在虚拟笛卡尔坐标系的原点位置，而接收机则在水下空间进行缓慢移动并接收数据。通过这种方式，我们成功构建了一个贴近实际通信环境的仿真场景，以评估本 SGD 方案的性能。如图4-1所示，我们选取了一些信号采样点作为本 SGD 方案仿真实现中的训练数据以及测试数据集信道条件，每个平面左下角的数字 $z_n$ 代表该平面在虚拟笛卡尔坐标系中可表示为 $z = z_n$。该仿真中使用的主要参数数值见表4-1。

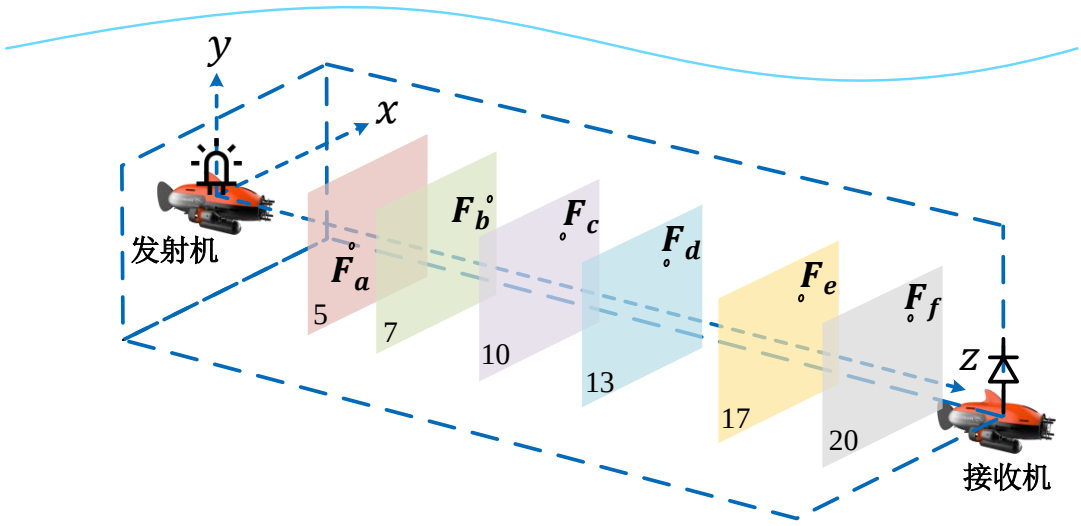


图 4-1 仿真设置示意图

表 4-1 仿真中使用的主要参数

| 参数 | 数值 |
|---|---|
| 发射光子数 | $10^9$ |
| 接收器处的光子权重阈值 | $10^{-6}$ |
| 光源波长 | 512nm |
| LED 发散角 | 10° |
| PD 光圈 | 0.2m |
| 接收机半 FOV 角 | 40° |
| 海水中的光速 | $2.25\times10^8 m/s$ |
| 水体类型 1，{衰减率，吸收率} | 沿海，{0.398，0.179} |
| 水体类型 2，{衰减率，吸收率} | 港口，{2.17，0.295} |
| DCO-OFDM 的直流偏置 | 13dB |
| OOFDM 的子载波数，N | 64 |
| CP 长度 | 32 |
| 调制星座图方式 | QPSK |
| DNN 检测器的线下训练位置 $h_a$ | $F_a$(0.2,0,5) |
| CGAN 线下训练位置 $h_b$ | $F_b$(1,0.5,7) |
| CycleGAN 线下训练位置 $h_b$ | $F_b$(1,0.5,7) |
| CGAN 线上更新性能测试位置 $h_c$ | $F_c$(0.2,0.5,10) |
| Siamese 训练位置 $h_d$、$h_e$ | $F_d$(0.2,0.5,13)、$F_e$(0.2,0.5,17) |
| Siamese 性能测试位置 $h_f$ | $F_f$(0.2,0.5,20) |

本研究采用蒙特卡洛方法[33] 模拟了在水环境中 LED 光源所对应的水下信道冲激响应 $h(t)$。蒙特卡洛方法是一种基于概率统计的数值模拟方法，通过随机抽样来模拟光子在水中的散射、吸收等物理过程。通过大量模拟光子的运动轨迹，我们可以获得光子的空间分布、时间分布以及能量分布等信息，进而分析光源在水中的传播特性。在本设计的仿真中，我们通过生成接收光子数据集并对其分类加权得到水下信道的冲激响应 $h(t)$。

其中，生成接收光子数据集的具体实现步骤为：

1）参数设定：首先，根据表4-1设定模拟参数，包括光子数量、光源波长、LED 发散角、PD 光圈、接收机半 FOV 角等；

2）生成散射角分布和衰减系数：根据表2-1给定的水体类型和散射模型，计算并返回了描述光子在水中的散射角分布和能量衰减系数，从而实现了对水下可见

光通信中光子散射特性和能量衰减情况的模拟[54]；

3）执行蒙特卡洛模拟：使用蒙特卡洛方法模拟光子从发射到接收的整个过程。在模拟过程中，根据光子的当前位置、方向和能量，计算其下一步的位置、方向和能量，并判断是否发生散射或吸收等物理过程。重复此过程直至光子到达探测器或被完全吸收；

4）数据处理与保存：将仿真结果（光子的位置、时间、权重等）保存，以便后续进行信道冲激响应的生成。

获得接收光子数据集后，我们通过以下步骤实现水下信道冲激响应的仿真：

1）初始化参数：首先设定模拟所需的参数，包括光子数量、循环次数、模拟区域的大小、探测器的直径、速度因子、网格分辨率、光速等；

2）读取模拟数据：读取接受光子数据集中的光子接收时间、接收位置、动量和权重等信息；

3）确定时间范围和索引：根据给定的时间分辨率和最大接收时间，计算时间索引的起始和结束值，并生成一个时间索引向量；

4）计算接收特性：通过两层循环，遍历每一个接收到的光子。首先找出位于接收点附近的光子，接着确定光子的接收时间是否落在指定的时间范围内。对于满足这两个条件的光子，将其动量与权重的乘积累加到冲激响应中的相应位置；

5）归一化结果：完成所有光子的遍历后，将冲激响应 $h(t)$ 除以光子总数和循环次数进行归一化，以得到每个接收点和时间间隔内平均接收的光子动量；

6）保存结果：将仿真结果 $h(t)$ 保存，以便后续进行仿真信号的传输，信号的传输方法如第2.2节所示。

在线下训练的过程中，我们选取信噪比（Signal Noise Ratio，SNR）为 10，20，30，40，50dB 五个典型值以及湍流系数 $\sigma_I^2$ 为 0.1，0.5，0.8，1.0 四个典型值进行 DNN 检测器的训练。具体来说，首先将 $SNR = 10dB$，$\sigma_I^2 = 0.1$ 的低信噪比弱流环境接收信号输入 DNN 检测器进行训练，经过最大训练步数为 100 步迭代训练，即每步的 DNN 权重为前一次训练的结果，接着将该权重结果运用于 $SNR = 20dB$，$\sigma_I^2 = 0.1$ 接收信号的迭代训练过程中，同理，对 $SNR = 30dB$，$40dB$ 进行相同的迭代训练，然后在 $SNR = 50dB$ 的高信噪比条件下，将最大训练步数变为 1000 次。为了使 DNN 检测器可以满足不同湍流环境要求的鲁棒解调，接下来对 $\sigma_I^2 = \{0.5, 0.8, 1.0\}$ 进行最大训练步数为 1000 步的迭代训练，最终得到 DNN 检测器的权重 $w_{DNN}$，也就是说，在 $SNR = 50dB$ 的情况下我们进行了最大步数为 4000 步的训练。训练过程中，由于数据样本并不包含所有可发送的比特信息，因此为了缓解过度拟合的问题，提高计算速率，我们采用了 Dropout 率为 $\eta = 0.1$ 的 DPL[55] 实现 DNN 检

测器的训练。线下训练中各神经网络的主要参数如表4-2所示，其中 CycleGAN 中生成器 $G$ 与 $F$ 的网络结构参数相同，判别器 $D_X$、$D_Y$ 的网络结构参数相同。

对于 CGAN 信道转换与检测器的线下训练过程，我们将 $SNR = 50dB$ 以及 $\sigma_I^2 = 0.1$ 的高信噪比低湍流的理想条件接收信号用于 SGD 的线下训练，在 CGAN 训练中，我们采用与 DNN 检测器相同的 Dropout 率。而对于 Siamese 线上更新控制器的线下训练过程，我们也使用 $SNR = 50dB$ 以及 $\sigma_I^2 = 0.1$ 的理想条件接收信号进行训练，从而是网络结构更精确地提取信道特性，在接收信号的相似度判别上获得更好的准确度。

为了实现方案性能的比较，我们在该系统中引入了传统的基于 LS 和 LMMSE 的信道估计方法[53] 以及理想 CSI 用于与本 SGD 方案进行对比，它们采用最大似然估计法（Max Likelihood Detection，MLD）作为信号检测方案。具体地说，LS 算法基于最小似然准则，设当前有一线性模型 $\mathbf{y} = \mathbf{X}\mathbf{h} + \mathbf{z}$，其中 $\mathbf{y}$ 为接收信号向量，$\mathbf{X}$ 为发送信号矩阵（导频），$\mathbf{h}$ 为信道响应，$\mathbf{z}$ 为噪声向量，则 LS 估计的数学表达式为：

$$\hat{\mathbf{h}}_{\mathrm{LS}} = (\mathbf{X}^{\mathrm{H}}\mathbf{X})^{-1}\mathbf{X}^{\mathrm{H}}\mathbf{y} \tag{4.1}$$

而 LMMSE 算法则是在 MMSE 信道估计的基础上进行线性平滑的结果，其估计可以表达为：

$$\hat{\mathbf{h}}_{\mathrm{LMMSE}} = \mathbf{R}_{\mathbf{hh}}\left[\mathbf{R}_{\mathbf{hh}} + \frac{\beta}{\mathrm{SNR}}\right]^{-1}\hat{\mathbf{h}}_{\mathrm{LS}} \tag{4.2}$$

其中，$\beta$ 是一个依赖于星座图的常数，其表达式为 $\beta = E[|x_k|^2]/E[|1/x_k|^2]$，在本 SGD 采用的 QPSK 调制中，$\beta = 1$，不仅如此，LMMSE 方法中均值和信道状态自相关矩阵等先验条件均可在训练位置或测试位置处计算。

为了实施传统的 LS 和 LMMSE 方案，我们在图2-3中去除了 CGAN 信道转换与检测器模块，并将 DNN 检测器替换为上述传统方案，从而在控制 CP 数量，导频数量等变量的前提下实现了参考系统误码率性能的测试。

表 4-2 神经网络主要参数

| 参数 | 数值 |
|---|---|
| 通用参数[26] | |
| 优化方法 | Adam 优化器[56] |
| 训练/测试数据集大小 | $10^5$ 个输入向量样本 |
| 验证集比例 | 0.1 |
| Dropout 率 $\eta$ | 0.1 |
| *DNN* 检测器参数 | |
| DNN 网络参数 | {1,{6},{16},{6};3,{384,128,62}} |
| DNN 输入维度 | 128×1 实数符号（64 个复数符号中的实部与虚部） |
| 训练数据集批次大小 | 1000×128×1 实数符号 |
| 训练条件 {SNR，$\sigma_I^2$，步数} | {10dB,0,1,100}，{20dB,0.1,100}，{30dB,0.1,100}，{40dB,0.1,100}，{50dB,0.1,1000}，{50dB,0.5,1000}，{50dB,0.8,1000}，{50dB,1.0,1000} |
| DNN 输出维度 | 62×1 比特符号 |
| *CGAN/ CycleGAN* 信道转换与检测器参数 | |
| 生成器网络参数 | {1,{6},{8},{4};2,{256,128}} |
| 生成器输入维度 | 144×1，128×1 实数符号与 16×1 噪声 |
| 生成器输出维度 | 128×1 生成符号 |
| 判别器网络参数 | {1,{6},{8},{4};2,{32,1}} |
| 判别器输入维度 | 128×1 真实数据或生成符号 |
| 判别器输出维度 | 1×1 判别结果 |
| 训练数据集批次大小 | 1000×144×1 实数符号（生成器），1000×128×1 实数符号（判别器） |
| 训练条件 {SNR，$\sigma_I^2$，步数} | {50dB,0.1,200} |
| *Siamese* 线上更新控制器参数 | |
| Siamese 网络参数（单个） | {1,{6},{8},{4};1,{32}} |
| Siamese 输入维度 | 256×1，两个 128×1 实数符号连接 |
| 训练数据集批次大小 | 1000×256×1 实数符号 |
| 样本对数量（包含正/负样本对） | 10（每 OOFDM 符号） |
| 训练条件 {SNR，$\sigma_I^2$，步数} | {50dB,0.1,1000} |
| Siamese 输出维度 | 1×1 收敛步数 |

## 4.2 基于 CGAN-DNN 联合检测的 SGD 方案在不同水体中的性能

本小节主要对本 SGD 在训练信道以及测试信道的误码率性能进行展示与介绍，分为以下三个部分：DNN 检测器，CGAN 信道转换与检测器的线下训练以及 CGAN 信道转换与检测器的线上更新。

### 4.2.1 DNN 检测器性能

使用2.4、4.1节所示的网络结构以及训练方法对 DNN 检测器进行训练，并讲训练后的 DNN 检测器在训练信道上进行信号恢复，计算其误码率性能并与传统检测方法进行误码率对比，其结果如图4-2、4-3所示，其中图4-2为沿海环境信道下 DNN 检测器的误码率性能比较，而图4-3为港口环境信道下的 DNN 检测器的误码率性能对比。

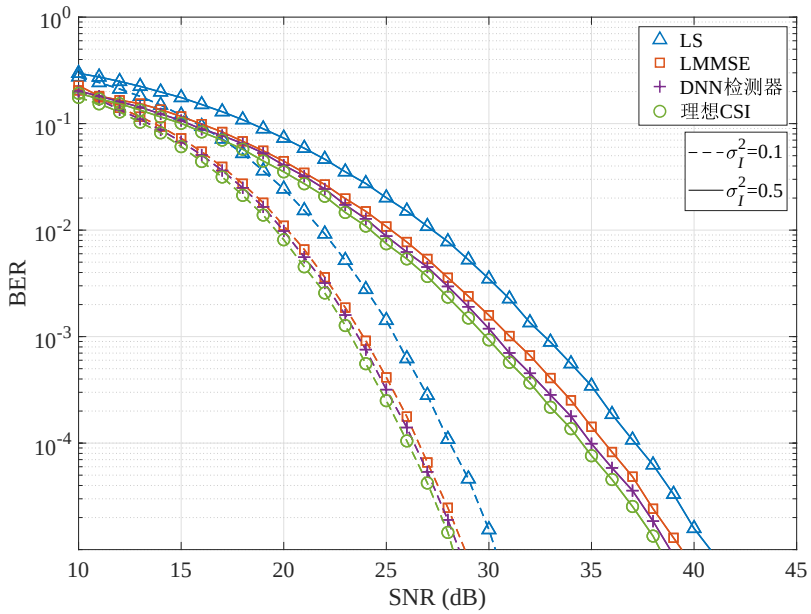


图 4-2 沿海环境信道下 DNN 检测器的 BER 性能比较

我们比较了 DNN 检测器方案与传统 LS 和 LMMSE 的信道估计方法在不同湍流方差以及不同水体环境下的 BER 性能。可以明显看出，训练信道中，在不同湍流方差以及不同水体环境下，使用 DNN 检测器进行信号的恢复比传统方法具有更好的性能。具体地说，我们以 $\gamma = 10^{-5}$ 作为目标误码率，如图4-2所示，$\sigma_I^2 = 0.1$ 的湍流系数干扰下，DNN 检测器相比于传统 LMMSE 以及 LS 方法分别具有大约 0.4dB 和 1.7dB 的增益，而在 $\sigma_I^2 = 0.5$ 的较高湍流干扰情况下，DNN 检测器相比于传统 LMMSE 以及 LS 方法分别具有大约 0.6dB 以及 2dB 的性能增益；如图4-3所示，$\sigma_I^2 = 0.1$ 下，DNN 检测器相比于传统 LMMSE 以及 LS 方法分别具有大约 2.5dB 和

4.8dB 的增益，而在 $\sigma_I^2 = 0.5$ 下，DNN 检测器相比于传统 LMMSE 以及 LS 方法分别具有大约 3.4dB 以及 5.8dB 的性能增益。可见在不同的水体环境下，DNN 检测器都可以获得相比 LS 以及 LMMSE 方法的误码率增益，这归功于 DNN 高效的特征识别以及提取能力，学习输入信号的信道特征以及发射与接收 OFDM 符号的映射特征，从而获得误码率的性能增益。不仅如此，在湍流系数较高的情况下，DNN 检测器可获得更好的性能增益，并且 DNN 检测器更加贴近理想 CSI 的性能。同时可以看到，在较为浑浊的水体中（吸收率，反射率增加），传统方法的误码率性能恶化，DNN 检测器相对于传统方法可获得更大的误码率性能增益。

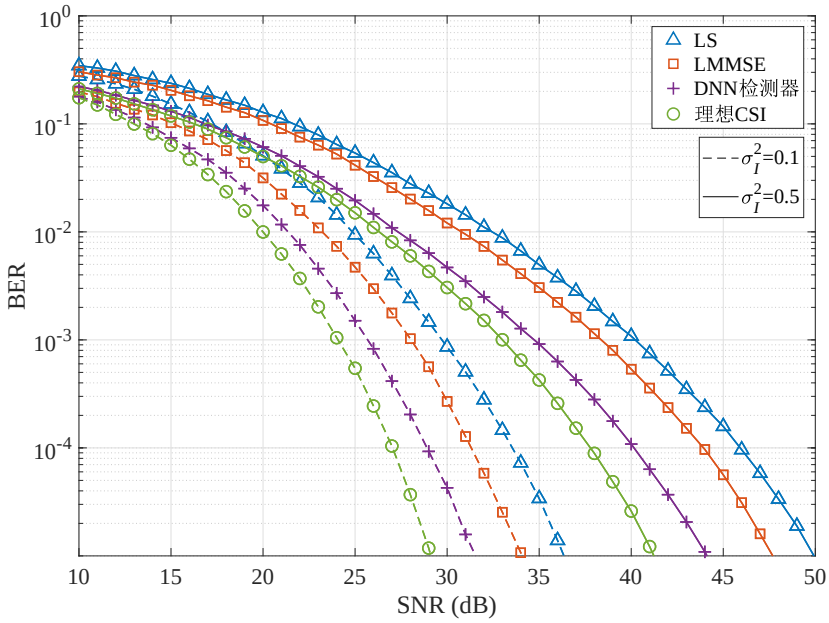


图 4-3 港口环境信道下 DNN 检测器的 BER 性能比较

### 4.2.2 CGAN 信道转换与检测器的线下训练性能

使用2.5、4.1节所示的网络结构以及训练方法对 CGAN 信道转换与检测器进行训练，以获得其对信道特征的转换能力，并将其部署于训练信道，与 DNN 检测器进行级联，进行信号恢复测试并计算其误码率性能，与传统检测方法进行误码率对比。其结果如图4-4、4-5所示，其中图4-4为沿海环境信道 CGAN 信道转换与检测器的误码率性能比较，而图4-5为港口环境信道下的 CGAN 信道转换与检测器的误码率性能对比。由图可知，进行线下训练后的 CGAN-DNN 联合检测方案相比于 LS，LMMSE 有更好的误码率性能。具体地说，以 $\gamma = 10^{-5}$ 作为目标误码率，由图4-4，在 $\sigma_I^2 = 0.1$ 的湍流系数干扰下，线下训练的 SGD 方案相比于传统 LMMSE 以及 LS 方法分别具有大约 1.3dB 和 2.1dB 的增益，而在 $\sigma_I^2 = 0.5$ 的较高湍流干扰情况下，线下训练方案相比于传统 LMMSE 以及 LS 方法分别具有大约 1.6dB 以

及 2.3dB 的性能增益；由图4-5可得，$\sigma_I^2 = 0.1$ 下，线下训练 SGD 方案相比于传统 LMMSE 以及 LS 方法分别具有大约 2.6dB 和 5.9dB 的增益，而在 $\sigma_I^2 = 0.5$ 下，线下训练 SGD 方案相比于传统 LMMSE 以及 LS 方法分别具有大约 3.7dB 以及 6.3dB 的性能增益。由此可见在湍流系数较高的情况下，SGD 方案相对于传统方法可获得更好的性能增益，不仅如此，在较浑浊的水体中线下训练 SGD 方案相比于传统方法增益更明显。由上述对比可得，CGAN 信号转换与检测器在不同水体中都能获得相比于 LS 以及 LMMSE 方法的误码率性能增益，这得益于 CGAN 作为生成对抗网络的信号生成能力以及同样作为深度神经网络的高效特征提取能力，在与判别器的不断对抗过程中学习了两种信道的特征以及发射信号到接收信号的映射关系，从而可以实现同发射信号下的信道特征转换。不仅如此，在水体质量下降（吸收率，反射率增加，湍流效应变强）的情况下，由于 CGAN 引入了噪声向量 **z** 作为输入，其对水体影响的鲁棒性更高，从而获得了相较于传统方法更大的误码率性能增益。

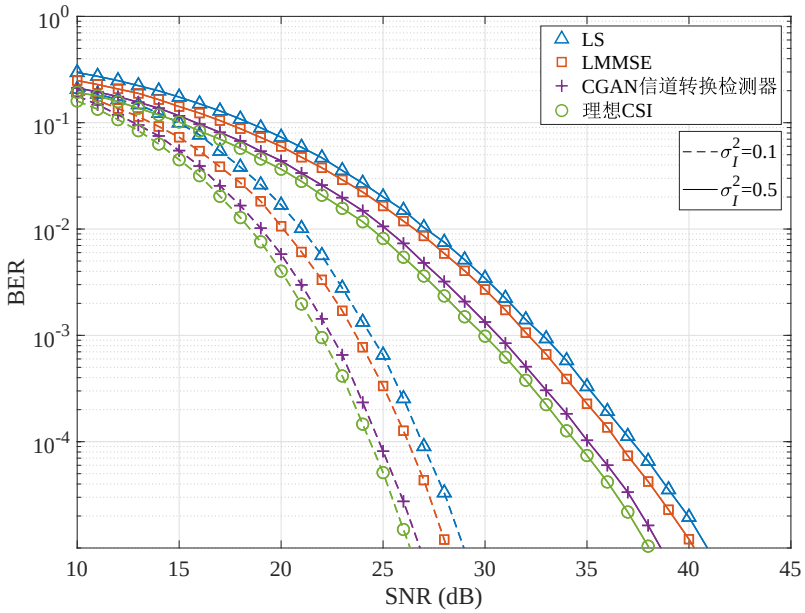


图 4-4 沿海环境信道 CGAN 信道转换与检测器的 BER 性能比较

### 4.2.3 CGAN 信道转换与检测器的线上更新性能

使用2.5、3.2、4.1节所示的网络结构以及训练方法对 Siamese 线上更新控制器进行线下训练，同时与 CGAN 信道转换与检测器级联进行受控制的线上更新，以获得本 SGD 设计对非训练信道特征的转换能力，并将其部署于测试信道，与 DNN 检测器进行级联，进行信号恢复测试并计算其误码率性能，与传统检测方法进行误码率对比。其结果如图4-6、4-7、4-8所示，其中图4-7为沿海环境信道 CGAN 信道转

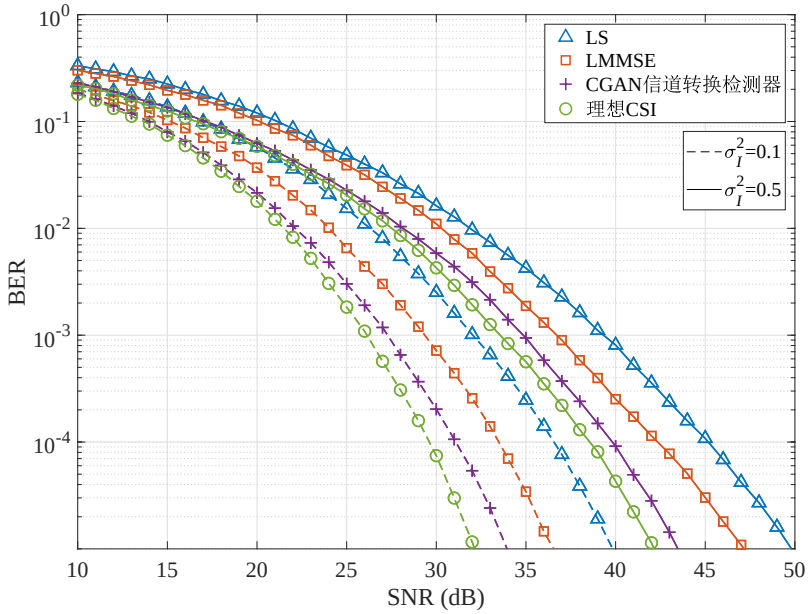


图 4-5 港口环境信道 CGAN 信道转换与检测器的 BER 性能比较

换与检测器的误码率性能比较，而图4-8为港口环境信道下的 CGAN 信道转换与检测器的误码率性能对比，在图4-8中，由于湍流指数在 $\sigma_I^2 = 0.1$ 以及 $\sigma_I^2 = 0.5$ 的误码率性能图像有较大的重叠部分，为方便观察，将其分为两图展示，其中图4-8a为 $\sigma_I^2 = 0.1$ 时的误码率性能，图4-8b为 $\sigma_I^2 = 0.5$ 时的误码率性能。由图4-6可知，当测试信道与训练信道较为接近时，线上更新时的误码率大约在第五步时就达到稳定，因此满足 SGD 设计线上更新的实时性要求。

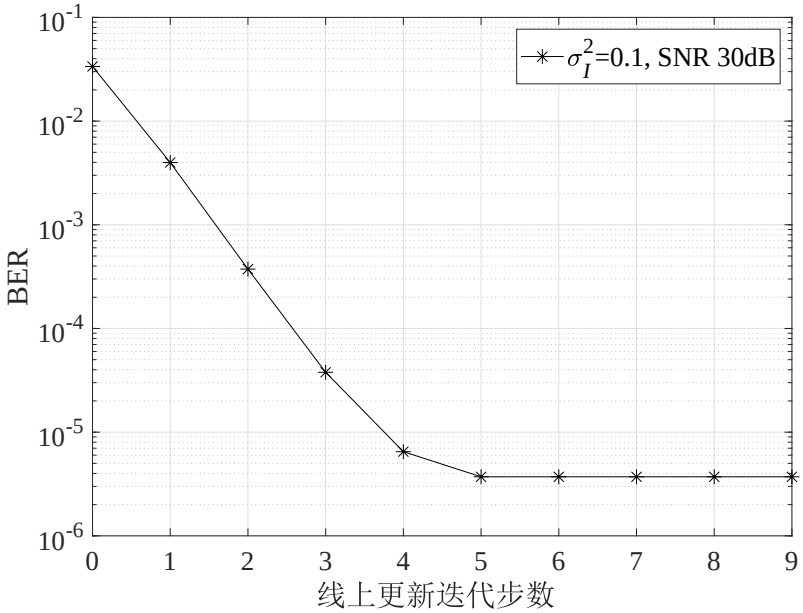


图 4-6 线上更新误码率变化

由图可知，线上更新的 CGAN-DNN 联合检测 SGD 方案相比于 LS，LMMSE

以及不考虑 CSI 的 DNN 检测器有更好的误码率性能。具体地说，取目标误码率为 $\gamma = 10^{-5}$，如图4-7所示，$\sigma_I^2 = 0.1$ 的湍流系数干扰下，线下训练的 SGD 方案相比于传统 LMMSE、LS 方法以及不考虑 CSI 的 DNN 检测器分别具有大约 0.8dB、1.2dB 和 2.2dB 的增益，而在 $\sigma_I^2 = 0.5$ 的较高湍流干扰情况下，DNN 检测器相比于传统 LMMSE、LS 方法以及不考虑 CSI 的 DNN 检测器分别具有大约 0.9dB、1.5dB 以及 2.5dB 的性能增益；由图4-8a可得，$\sigma_I^2 = 0.1$ 下，线下训练 SGD 方案相比于传统 LMMSE，LS 方法以及不考虑 CSI 的 DNN 检测器分别具有大约 4.4dB、9.9dB 和 14dB 的增益，由图4-8b可得，在 $\sigma_I^2 = 0.5$ 下，线下训练 SGD 方案相比于传统 LMMSE，LS 方法以及不考虑 CSI 的 DNN 检测器分别具有大约 5.7dB、11.2dB 以及 17.7dB 的性能增益。可见在湍流系数较高的情况下，SGD 方案相对于传统方法可获得更好的性能增益，并且本 SGD 方案更加贴近理想 CSI 的性能。

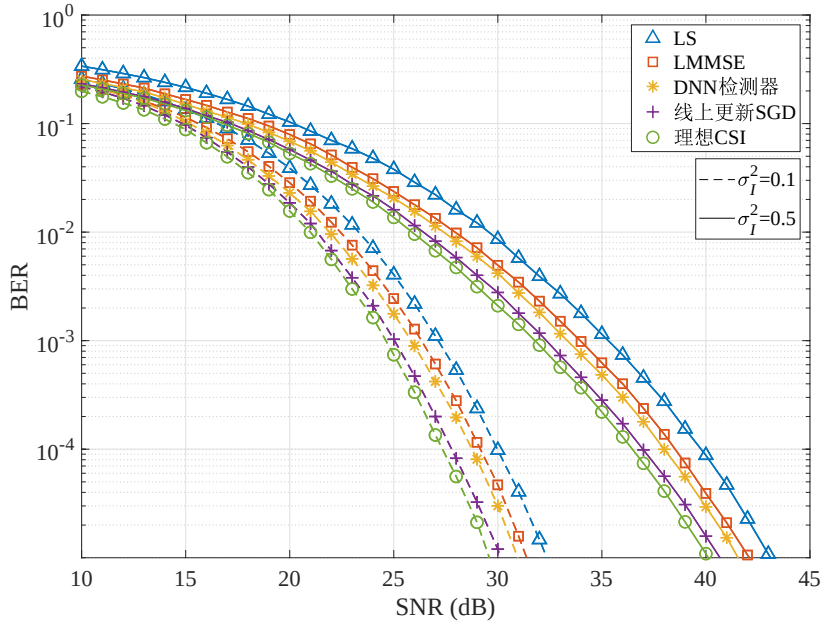


图 4-7 沿海环境信道线上更新 SGD 的 BER 性能比较

不仅如此，在较恶劣的水体环境中基于 Siamese 网络进行 CGAN-DNN 线上更新联合检测的 SGD 方案相比于传统方法增益更明显。除此之外，由图4-7可以看到理想 CSI 的性能在 $\sigma_I^2 = 0.1$ 的湍流系数干扰下达到目标误码率的信噪比为 29.6dB，而在 $\sigma_I^2 = 0.5$ 的湍流系数干扰下达到目标误码率的信噪比为 40.1dB，高于图4-2、4-4的对应达到目标误码率的信噪比，这是因为仿真所选择的信道中，$h_c$ 为在水下与虚拟坐标系原点水平距离为 10m 的信道，而 $h_b$，$h_a$ 分别为水下与虚拟坐标系原点水平距离为 7m，5m 的信道，因此距离较远的 $h_c$ 信号衰减更为明显，到达目标误码率所需要的信噪比也会相对较高。根据上述分析，本 SGD 线上更新方案在不同水下信道条件下，无论是对传统的 LS、LMMSE 信道估计算法以及深度学习领

域的单 DNN 检测器解调算法，都有着不低的性能增益，这是因为 CGAN 信道转换与检测器实现了 DNN 检测器的信道匹配，从而使接收信号无论来自何种信道，都可以被转化为 DNN 检测器可识别的信道特征，在 UWOC 中获得较低的误码率。

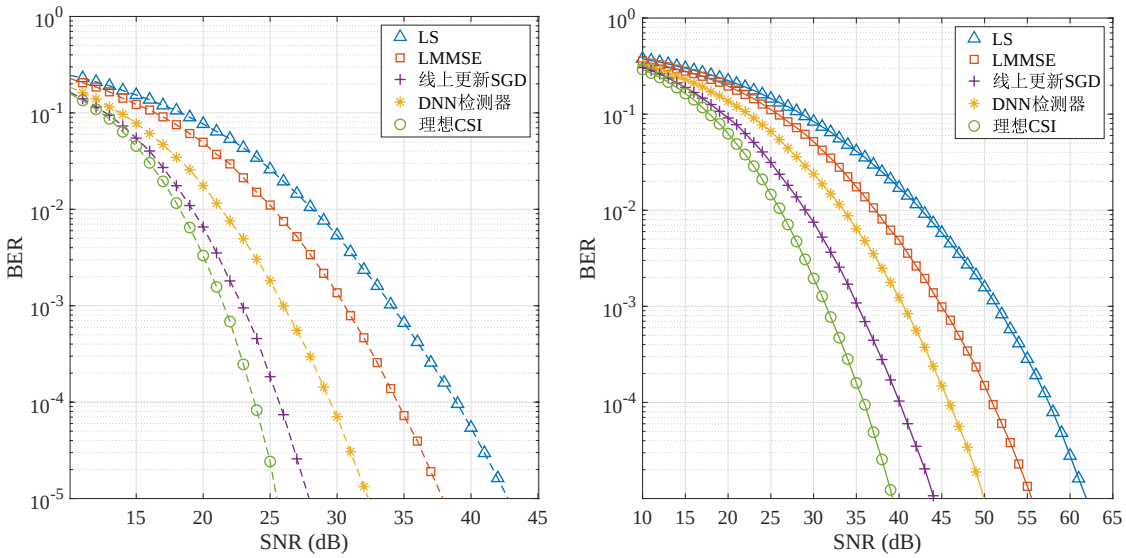


(a) $\sigma_I^2 = 0.1$ (b) $\sigma_I^2 = 0.5$

图 4-8 港口环境信道线上更新 SGD 的 BER 性能比较

## 4.3 基于 Siamese 网络的线上更新性能

由3.2节可得，Siamese 线上更新控制器学习接收信号的信道特征并与 CGAN 信道转换与检测器的训练信道特征进行比对，从而获取相似度度量，预测 CGAN 信道转换与检测器线上更新达到收敛所需要的训练步数，从而减小线上训练时 CGAN 信道转换与检测器由于过度训练而产生的开销。本节将从误码率性能以及复杂度两个方面对基于 Siamese 网络的线上更新性能进行介绍。

### 4.3.1 基于 Siamese 线上更新控制器的 SGD 误码率性能

采用3.2、4.1节的网络结构以及训练环境对 Siamese 网络进行训练，并对使用 Siamese 进行 CGAN 信道转换与检测器的线上更新误码率性能以及对 CGAN 信道转换与检测器进行固定更新步数线上更新的误码率性能进行对比，为了使所有在线部署信道特性都能得到充分的学习与更新，我们取线上更新的固定步数 $e = 10$。结果如图4-9所示，图中展示了 $h_d$、$h_e$、$h_f$ 三种信道下的误码率性能，并与 $h_d$ 信道的理想信道误码率与 LMMSE 方法的误码率进行了对比。由图可知，在三种不同的信道下，Siamese 线上更新控制器的存在并不会因为减少了训练步数从而带

来误码率性能的下降，这是因为 Siamese 线上更新控制器精准提取了该信接收信号的信道特征并预测了 CGAN 信道转换与检测器的更新收敛步数，此外，图中有 Siamese 以及无 Siamese 的曲线并未完全重合，这是因为 CGAN 网络有随机噪声作为输入，因此在最终的收敛的网络权重上并不完全一致。不仅如此，在测试信道中基于 Siamese 线上更新控制器的 CGAN-DNN 联合检测 SGD 方案相比于传统 LMMSE 方法依然有较大的误码率性能增益，侧面应证了4.2.3小节中的结论。

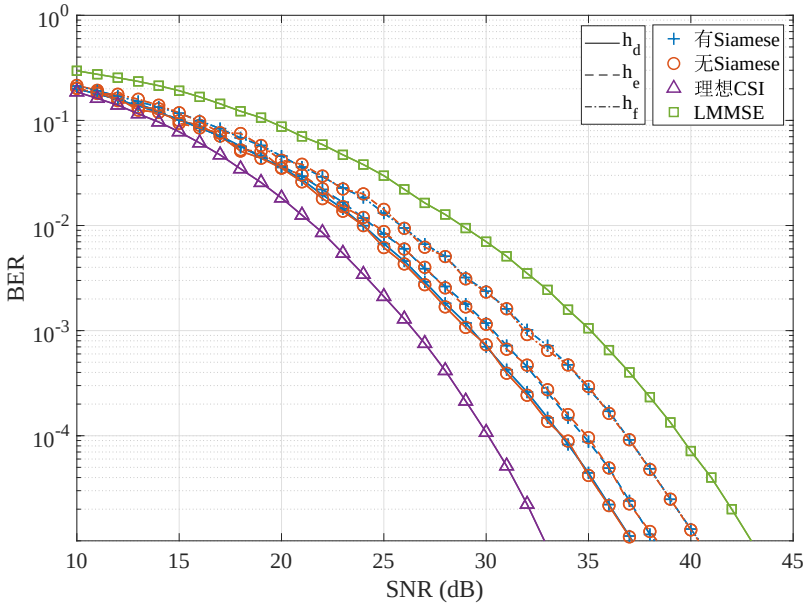


图 4-9 Siamese 线上更新控制器的误码率性能对比

### 4.3.2 基于 Siamese 线上更新控制器的 SGD 复杂度

在本小节中，我们将对各种接收机的复杂度进行对比，包括一个 OFDM 符号的浮点运算（Floating Points of Operations，FLOPs）数量，深度学习网络权重存储空间以及 UWOC 系统中完成 N=64 个子载波的一个 OFDM 符号的单个前向传播所需要的执行时间。如表4-3所示。

在传统的 LS 参考系统中，对于每一个 OFDM 符号需要进行两次复数除法，而每个复数除法需要 11 次 FLOPs，因此其每 OFDM 符号的总 FLOPs 数量可表示为：

$$(\text{FLOPs})_{\text{LS}} = 11N + 11N = 11 \cdot 64 \cdot 2 = 1,408 \tag{4.3}$$

而在 LMMSE 参考系统中，对于信道的估计与信号的恢复需要进行复杂的矩阵运算以及矩阵的求逆[53]，由文献[57] 得，其 FLOPs 数量为 $1.6\times10^6$。

对于深度学习网络中的 FLOPs 数量计算，本研究中我们计算浮点加法以及浮

点乘法之和，深度学习网络中的 CL 层以及 FCL 层的 FLOPs 数量可做推导如下：

首先，对于本设计中所用的一维的 CL 层，如图4-10所示，假设其每通道输入维度为 $x_{N_{in}} \times 1$，输入通道数为 $C_{in}$，其值为 $\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1C_{in}} \\ \vdots & \ddots & \vdots \\ x_{N_{in}1} & \cdots & x_{N_{in}C_{in}} \end{bmatrix}$，而卷积核高度为 $H \times 1$，其值为 $\mathbf{w} = [w_1, w_2, \cdots w_H]$，每通道输出维度为 $y_{N_{out}} \times 1$，输出通道数为 $C_{out}$，其值为 $\mathbf{Y} = \begin{bmatrix} y_{11} & \cdots & y_{1C_{out}} \\ \vdots & \ddots & \vdots \\ y_{N_{out}1} & \cdots & y_{N_{out}C_{out}} \end{bmatrix}$，则卷积输出值可用以下公式计算（以 $y_{11}$ 为例）：

$$y_{11} = x_{11}w_1 + x_{12}w_2 + ... + x_{1H}w_H \tag{4.4}$$

可见在每一个卷积输出值的计算中，都包含了 $H$ 次浮点乘法以及 $H-1$ 次浮点加法的运算，因此，一维 CL 层的 FLOPs 数量计算公式为：

$$(\text{FLOPs})_{\text{CL}} = (H + H - 1) \cdot C_{out} \cdot N_{out} = (2H - 1) \cdot C_{out} \cdot N_{out} \tag{4.5}$$

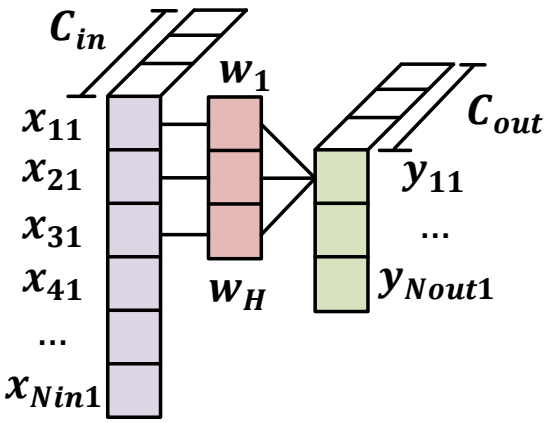


图 4-10 一维 CL 层结构示意图

而在本设计中，由于我们在 CL 层后加入了 BN 层[45]，因此在每层中还有两个

参数 $\alpha$、$\beta$ 需要进行计算，故添加 BN 层的一维 CL 层 FLOPs 数量计算公式为：

$$(\text{FLOPs})_{\text{CL BN}} = (2H - 1 + 2) \cdot C_{out} \cdot N_{out} = (2H + 1) \cdot C_{out} \cdot N_{out} \tag{4.6}$$

接下来分析 FCL 层的 FLOPs 数量，如图4-11所示, 假设其输入维度为 $x_{N_{in}} \times 1$，其值为 $\mathbf{x} = [x_1, x_2, \cdots x_{N_{in}}]$，输出维度为 $y_{N_{out}} \times 1$，其值为 $\mathbf{y} = [y_1, y_2, \cdots y_{N_{out}}]$，则全连接层输出值可用以下公式计算（以 $y_1$ 为例）：

$$y_1 = x_1 w_1 + x_2 w_2 + x_3 w_3 + x_4 w_4 + \cdots + x_{N_{in}} w_{N_{in}} \tag{4.7}$$

其中 $\mathbf{w} = [w_1, w_2, ...w_{N_{in}}]$ 为 FCL 层中 $\mathbf{x}$ 映射到 $y_1$ 对应的网络参数，可见在每一个输出值的计算中，都包含了 $N_{in}$ 次浮点乘法以及 $N_{in} - 1$ 次浮点加法的运算，因此，FCL 层的 FLOPs 数量计算公式为：

$$(\text{FLOPs})_{\text{FCL}} = (N_{in} + N_{in} - 1) \cdot N_{out} = (2N_{in} - 1) \cdot N_{out} \tag{4.8}$$

接下来介绍本文中存储复杂度的计算方法，同样对深度学习网络中的 CL 层以及 FCL 层的存储复杂度的计算方法进行推导如下：

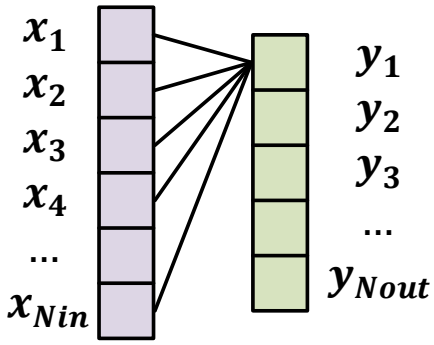


图 4-11 FCL 层结构示意图

CL 层中，对于每个输出通道需要存储一个大小为 $H \times 1$ 的卷积核以及 BN 层的参数 $\alpha$、$\beta$，其权重存储复杂度计算公式如下：

$$(\text{Param})_{\text{CL BN}} = (H + 2) \cdot C_{out} \tag{4.9}$$

表 4-3 各方案复杂度对比

| | FLOPs/ OFDM 符号 | 运行时间 (秒) | 网络权重 参数量 |
|---|---|---|---|
| *基础网络* | | | |
| DNN 检测器 | $3.38 \times 10^5$ | $6.6 \times 10^{-5}$ | $1.86 \times 10^5$ |
| CGAN 生成器 | $1.91 \times 10^5$ | $3.4 \times 10^{-5}$ | $1.04 \times 10^5$ |
| CGAN 判别器 | $0.18 \times 10^5$ | $0.4 \times 10^{-5}$ | $0.83 \times 10^5$ |
| Siamese 控制器 | $0.40 \times 10^5$ | $0.7 \times 10^{-5}$ | $0.88 \times 10^5$ |
| *无 Siamese 控制的 SGD 方案* | | | |
| 不更新 SGD | $5.87 \times 10^5$ | $1 \times 10^{-4}$ | $2.90 \times 10^5$ |
| 固定更新 SGD（$I_u = 10$） | $2.30 \times 10^6$ | $4.1 \times 10^{-4}$ | $2.90 \times 10^5$ |
| *Siamese 控制更新的 SGD 方案* | | | |
| 测试信道 $h_c$（$I_u = 5$） | $1.17 \times 10^6$ | $2.4 \times 10^{-4}$ | $3.78 \times 10^5$ |
| 测试信道 $h_d$（$I_u = 6$） | $1.36 \times 10^6$ | $2.8 \times 10^{-4}$ | $3.78 \times 10^5$ |
| 测试信道 $h_e$（$I_u = 8$） | $1.74 \times 10^6$ | $3.4 \times 10^{-4}$ | $3.78 \times 10^5$ |
| 测试信道 $h_f$（$I_u = 8$） | $1.74 \times 10^6$ | $3.4 \times 10^{-4}$ | $3.78 \times 10^5$ |
| *传统方案* | | | |
| LMMSE | $1.60 \times 10^6$ | $2.6 \times 10^{-2}$ | —— |
| LS | $1.41 \times 10^3$ | $3.5 \times 10^{-3}$ | —— |

而 FCL 层中，对于每个输出需要存储 $N_{in}$ 个权重参数，其权重存储复杂度计算公式如下：

$$(\text{Param})_{\text{FCL}} = N_{in} \cdot N_{out} \tag{4.10}$$

如表4-3所示，在不考虑 CSI 变化时，DNN 检测器可以在只需要不到传统 LMMSE 四分之一 FLOPs 数量的情况下提供较低的 BER 性能。而在 CGAN 信道转换与检测器的辅助下，本 SGD 可以在 UWOC 的 CSI 变化场景中提供鲁棒的且增益较大的 BER 性能，可以看到，在生成器不进行更新时，SGD 的计算复杂度约为 LMMSE 算法的三分之一，然而在需要进行线上更新的情况下，采用固定更新步数的 SGD 方案由于需要考虑收敛步数的余量，因此会有复杂度上的浪费。引入了 Siamese 线上更新控制器后，SGD 方案可以用较低的复杂度成本获取当前信号所在的信道状态，并控制 CGAN 信道转换与检测器线上更新的步数，从而精确预估收敛步数，避免由于多次重复 CGAN 生成器的更新而造成的复杂度上升。在测试信道 $h_c$ 及其他

与 CGAN 训练信道较为接近的实际部署信道中，由于收敛步数较小，因此采用了 Siamese 线上更新控制器的 SGD 方案复杂度明显低于不采用 Siamese 的固定更新 SGD，而随着水体变化增加，在测试信道 $h_d$ 条件下，采用了 Siamese 线上更新控制器的 SGD 方案复杂度逐渐接近 LMMSE 方案，甚至在 $h_e$、$h_f$ 的信道条件下小幅度超出了 LMMSE 的 FLOPs 数量，但本 SGD 方案相对于 LMMSE 方案仍能提供较大的误码率性能增益，且在缓慢变化的水下环境中，出现信道突变的概率较低，因此需要进行多步更新的情景较为罕见。不仅如此，本 SGD 方案所提出的 DNN 检测器，CGAN-DNN 联合检测方案以及 Siamese 控制的 CGAN-DNN 联合检测方案所需要的执行时间均远远低于传统的 LS 以及 LMMSE 方案，这是因为 LS 以及 LMMSE 方案调用了高复杂度的中央处理器（Central Processing Unit，CPU）矩阵求逆运算，而深度神经网络可以在图形处理器（Graphics Processing Unit，GPU）中进行并行运算，从而极大地降低网络训练以及计算所需要的时间。具体地说，在本设计中，基于 Siamese 控制更新的 SGD 方案在应用于测试信道 $h_c$ 时，在 Python3.8 平台上使用 NVIDIA® GeForce® GTX3090 型号的 GPU 可以在 $2.4 \times 10^{-4}$ 的时间内完成一次 OFDM 的处理，而相比之下，LS 和 LMMSE 参考系统在主流 CPU Intel® Core™ i7-14700KF 支持的 MATLAB® 平台上需要高出一到两个数量级的时间消耗。对于存储复杂度而言，传统的 LS 和 LMMSE 方案仅需存储自相关矩阵等先验知识，而 DNN 检测器等深度神经网络则需要额外存储网络权重从而固定优化后的性能。因此，基于 Siamese 控制的 CGAN-DNN 联合检测 SGD 方案相较于传统方案有着更高的存储需求。

## 4.4 CycleGAN-DNN 联合检测 SGD 方案在训练样本减少时的性能

根据4.1节的仿真参数对 CycleGAN 以及 CGAN 进行网络参数的设置，使用3.2.3、2.5.3小节的训练方法在减少训练样本的情况下对 CycleGAN 以及 CGAN 信道转换与检测器进行训练与测试，并使用与训练样本同样数量导频的 LS 以及 LMMSE 方法作为传统方法对比方案，在训练样本（或导频）减少 1/10，1/100 以及 1/1000 三种情况分别对以上四种方案进行了仿真测试，其结果如图4-12、4-13所示。本小节采用的测试环境均为沿海水体，其中，图4-12为训练样本或导频数量减少到原来的 1/10 所得到的误码率性能，具体地说，训练样本数量的减少针对 CGAN 以及 CycleGAN 信道转换与检测器的训练过程，而导频数量的减少则针对 LS 以及 LMMSE 方法的实现。图4-12a、4-12b分别对应湍流系数 $\sigma_I^2$ 为 0.1 以及 0.5 的情况。图4-13为训练样本或导频数量减少到原来的 1/1000 所得到的误码率性能，其中图4-13a、4-13b对

应湍流系数 $\sigma_I^2$ 为 0.1、0.5 的情况。

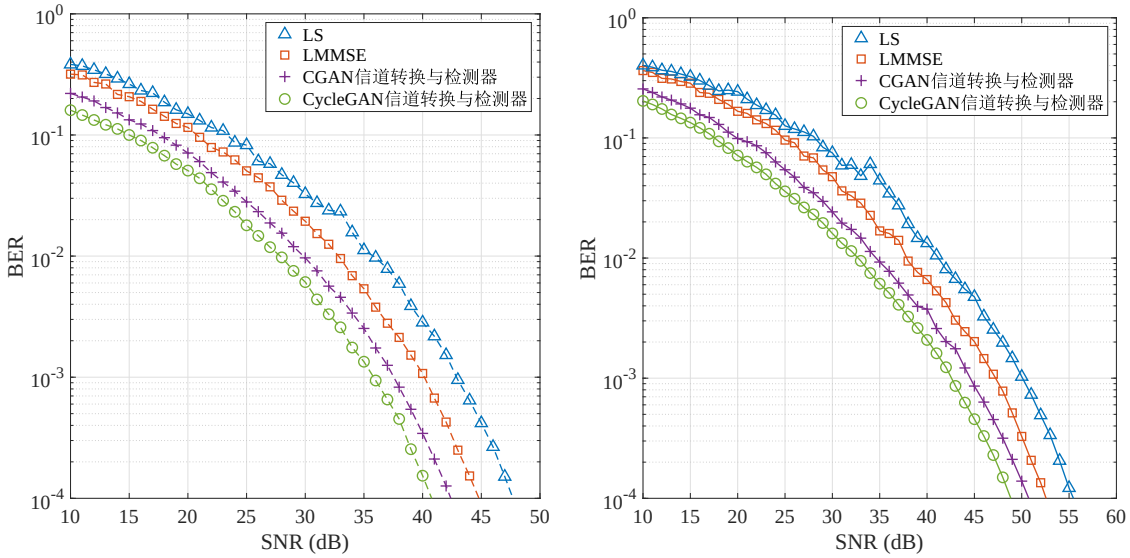


(a) $\sigma_I^2 = 0.1$ (b) $\sigma_I^2 = 0.5$

图 4-12 训练样本（或导频）数减少到 1/10 的误码率性能对比

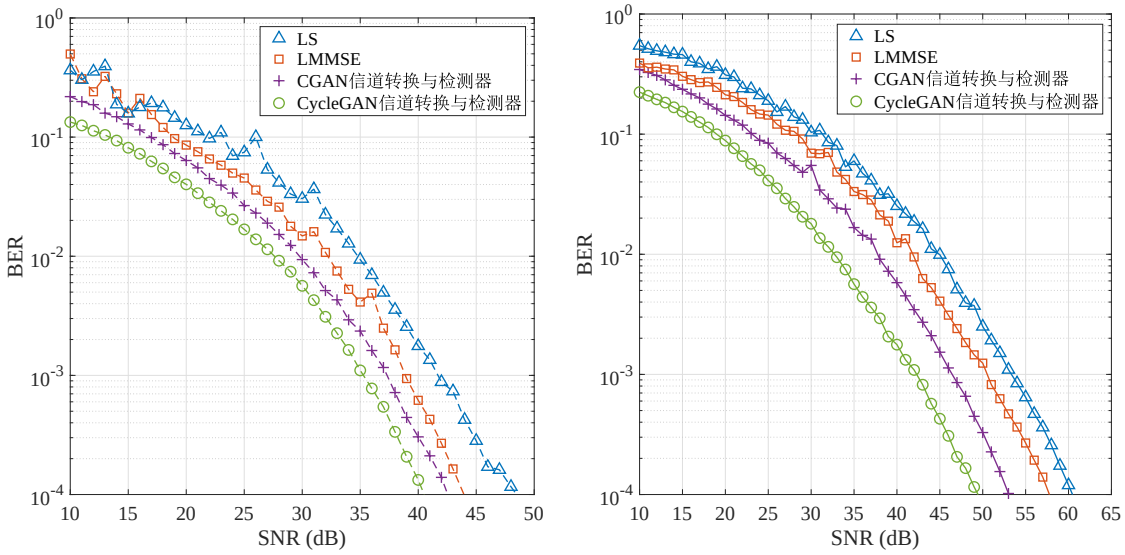


(a) $\sigma_I^2 = 0.1$ (b) $\sigma_I^2 = 0.5$

图 4-13 训练样本（或导频）数减少到 1/1000 的误码率性能对比

如图4-12所示，当训练样本或导频数量减少到原来的 1/10 时，传统检测方法 LMMSE 以及 LS 出现误码率性能的抖动，这是因为 LS 和 LMMSE 算法是基于导频的信道估计算法，当导频数量减少时，可用于信道估计的数据减少，导致估计的不确定性增加，信道估计的准确性下降，进而影响整个系统的性能。然而对于 CGAN 以及 CycleGAN 信道转换与检测器，由于使用深度学习方法进行特征提取与拟合，其误码率波动较不明显，然而对比图4-4中的结果可发现 CGAN 信道转换与检测器的误码率显著提高，CycleGAN 相比 CGAN 误码率较低，这归功于 CycleGAN 在

后半部分无监督学习中实现的精确特征提取以及语义保留。而对于图4-13，当训练样本或导频数量减少到原来的 1/1000 时，出现的误码率抖动幅度大幅提升，这是因为当导频信号大幅减少时，快速时变的 UWOC 信道变化无法被信道估计算法充分考虑，从而导致传统算法在下一个导频到来前均无法获知当前信道的状态，因此只能依靠此前的信道估计进行当前信号的解调，误码率性能不稳定，同样地，基于深度学习的 CycleGAN 以及 CGAN 信道转换与检测器误码率性能较为稳定，对比图4-4中的结果可发现 CGAN 的误码率性能提高，且 CycleGAN 相比 CGAN 误码率低。

综上所述，CycleGAN 信道转换与检测器在训练样本不同程度减少时可以实现相较于 CGAN 更低且更稳定的误码率水平，从而在训练样本减少的 UWOC 系统中维持系统的鲁棒性，然而在训练样本减少的 UWOC 系统中采用的 CycleGAN 信道转换与检测器误码率性能依然与理想 CSI 有较大的差距，距离实际应用的可行性仍存在一段距离，亟需进一步深入研究与探索。

# 第 5 章 总结与展望

随着人类对海洋的开发和探索不断深入，UWOC 技术逐渐成为下一代通信的研究热点。在水下环境中，光学通信技术相比于 UWA 以及 UW-RF 等技术因其较高的传输速率和带宽能力而备受关注。目前许多 UWOC 技术已进入商业试验阶段，UWOC 技术也被定义为实现 6G 的关键技术。然而，水下环境的复杂性和不确定性给 UWOC 系统的性能带来了巨大挑战，目前实现理想的水下通信仍需要进行大量的研究工作。深度学习作为一种先进的机器学习方法，已经在许多领域取得了显著的成果。近年来，将深度学习技术应用于 UWOC 领域成为研究趋势。本文围绕基于深度学习的 UWOC 技术展开研究，旨在利用深度学习算法对 UWOC 系统的误码率性能进行优化。通过对比传统的 UWOC 系统与基于深度学习的方法，本文证明了深度学习技术在 UWOC 领域具有的优势。本节将从工作总结以及研究展望两方面对本设计进行总结与展望。

## 5.1 工作总结

在本设计中，我们对应用于复杂时变的 UWOC 系统中的 CGAN-DNN 联合检测 SGD 方案提出了两种改进思路并进行了验证性仿真测试，其基本深度学习模块为 DNN，CGAN，Siamese 以及 CycleGAN 网络。大多数现有的 DNN 检测器方案仅依赖于线下训练过程，而通过线下的训练以及线上的受控更新迭代的 SGD 方案可以及时对当前 CSI 场景作出反应并追踪 CSI 的变化，通过信道特征转换功能进行接收信号的转换，最后基于信号检测功能进行接收信号的解调恢复，本文对上述工作在不同水体中的性能进行了测试，并基于线上更新时间复杂度高的问题提出了一种 Siamese 线上更新控制器，通过减少训练步数的方法降低了时间成本，不仅如此，本文还使用 CycleGAN 替代 CGAN 以节省采集训练数据所需要的开销。基于蒙特卡洛方法的仿真结果表明，在时变的 CSI 场景下，本 SGD 设计方案在误码率性能上优于传统的 LS 以及 LMMSE 信道估计方法，并且在浑浊水体中其相对增益更大，拥有较高的鲁棒性。不仅如此，Siamese 网络的引入极大地降低了线上更新所需要的复杂度，提高了线上更新的处理速度，使通信即时性大大提高，CycleGAN 则能在训练数据减少的情况下获得比 CGAN 以及导频减少的 LS、LMMSE 方案更好的性能。本文中提出的针对 CGAN 网络以及 Siamese 网络的分段式训练方法大大提高了网络的多目标学习能力，从而使 CGAN 网络提供更好的信号转换性能，

Siamese 网络实现更精确的收敛条件预测。

## 5.2 研究展望

本论文的工作仍存在一些不足，有待进一步研究。基于本文所研究的各项工作，以下总结本文不足之处和未来工作的展望。

1）对于 CGAN 信道转换与检测器的线上部署，神经网络对于某些特定符号组合具有不确定性，可能会出现误码率的突增，对于实时快速通信来说这是不允许的，需要找到更稳定的结构实现信道特性的转换；

2）不仅如此，在 CGAN 的线上更新过程中需要用到较多的导频符号进行新信道特征的学习，如何让 CGAN 实现更高效的特征提取也是一个值得研究的方向；

3）由于水下信道的多样性，在本文的测试信道中，并未出现与 CGAN 线下训练信道相似的信道，因此未对该类信道进行测量，无法获知本方案在该类信道下的其误码率性能；

4）在复杂度对比中，我们发现针对与训练信道差异较大的信道，该方案的线上更新复杂度依然较大，因此为了保证通信速率，该方案只能部署于信道变化较为缓慢的水体环境中，如何在变化剧烈的水体环境下部署高效率的线上更新解调器仍是值得研究的内容；

5）本文所研究的 CycleGAN 信道转换与检测器虽然能在训练样本数量较少的情况下实现更好的鲁棒性，但距离理想信道误码率性能依然有不小的距离，为了满足实际部署的需求，需要进一步对该方案进行优化和改进。

展望未来，我们相信深度学习技术在 UWOC 领域具有更广阔的应用前景。一方面，随着算法的不断优化和硬件设备的进步，深度学习技术有望进一步降低 UWOC 系统的误码率，提高通信速率。另一方面，深度学习技术可以与其他通信技术相结合，例如 MIMO、波分复用等，以实现更高效、更可靠的 UWOC 通信。此外，深度学习技术还可以应用于 UWOC 系统的故障检测和自动调参，进一步提高系统的稳定性和适应性。随着深度学习技术的不断发展和创新，UWOC 通信将迈向更高的性能水平，为水下信息传输带来更多的可能性和机遇。

# 参考文献


[1] ZENG Z, FU S, ZHANG H, et al. A Survey of Underwater Optical Wireless Communications[J]. IEEE Communications Surveys and Tutorials, 2017, 19(1) : 204 – 238.

[2] POMPILI D, AKYILDIZ I F. Overview of networking protocols for underwater wireless communications[J]. Communications Magazine IEEE, 2009, 47(1) : 97 – 102.

[3] KUMAR P, TRIVEDI V K, KUMAR P. Recent trends in multicarrier underwater acoustic communications[C] // Underwater Technology. [S.l.] : IEEE, 2015 : 1 – 8.

[4] KHALIGHI M A, GABRIEL C, HAMZA T, et al. Underwater Wireless Optical Communication; Recent Advances and Remaining Challenges[C] // International Conference on Transparent Optical Networks. 2016 : 1 – 4.

[5] JOHNSON L J, JASMAN F, LEESON M S, et al. Recent advances in underwater optical wireless communications[J]. Underwater technology: International journal of the society for underwater technology, 2014, 32(3) : 167 – 175.

[6] DUNTLEY S Q. Light in the Sea[J]. Journal of the Optical Society of America, 1963, 53(2) : 214 – 233.

[7] GILBERT G D, STONER T R, JERNIGAN J L. Underwater Experiments On The Polarization, Coherence, And Scattering Properties Of A Pulsed Blue-Green Laser[C] // Underwater Photo Optics I. [S.l.] : International Society for Optics and Photonics, 1966.

[8] FAIR N, CHAVE A D, FREITAG L, et al. Optical Modem Technology for Seafloor Observatories[C] // OCEANS 2006. Boston, MA, US : IEEE, 2006.

[9] HANSON F. High Bandwidth Underwater Optical Communication[J]. Applied Optics, 2008, 47(2) : 277 – 283.

[10] HAI-HAN. L, CHUNG-YI. L, HUNG-HSIEN. L, et al. An 8 m/9.6 Gbps Underwater Wireless Optical Communication System[J]. IEEE Photonics Journal, 2016, 8(5) : 1 – 7.

[11] TU C, LIU W, JIANG W, et al. First Demonstration of 1Gb/s PAM4 Signal Transmission Over A 130m Underwater Optical Wireless Communication Channel with Digital Equalization[J]. 2021 IEEE/CIC International Conference on Communications in China (ICCC), 2021 : 853 – 857.

[12] CHEN J, ZHAO L, JIANG M, et al. Sherman-Morrison Formula Aided Adaptive Channel Estimation for Underwater Visible Light Communication With Fractionally-Sampled OFDM[J]. IEEE Transactions on Signal Processing, 2020, 68 : 2784 – 2798.

[13] LIU X, ZHANG K, TANG X, et al. A Modified DFT-Based Channel Estimation Algorithm for Underwater Wireless Optical Links[C] // 2022 Asia Communications and Photonics Conference (ACP). 2022 : 795 – 799.

[14] LIU X, HU J, ZHANG K, et al. On Channel Estimation Based on Compressed Sensing for OFDM UWOC Systems[C] // 2022 Asia Communications and Photonics Conference (ACP). 2022 : 1039 – 1042.

[15] ZHANG L, ZHU H, SUN W, et al. Performance Analysis of Underwater Acoustic Automatic Modulation Classification System with Machine Learning[C] // 2021 IEEE 21st International Conference on Communication Technology (ICCT). 2021 : 1310 – 1314.

[16] 李晓记, 杜卫海, 李燕龙, et al. 基于 SVM 的水下 LED 可见光通信信号检测方法 [J]. 光通信技术, 2021, 45(05) : 50 – 54.

[17] 张仲丹. 基于机器学习的无线光通信和定位研究 [D]. [S.l.] : 中国矿业大学, 2022 年.

[18] 龙倩倩. 基于室内可见光通信系统的定位与调制技术研究 [D]. [S.l.] : 北京邮电大学, 2023 年.

[19] 叶鹏飞, 张鹏, 伍文韬, et al. 基于机器学习的水下光通信信道估计与信号解调算法仿真研究 [J]. 光电子 • 激光, 2024 : 1 – 9.

[20] ZHANG Z, ZHANG L, CHEN Z. Multi-Agent Reinforcement Learning Based Channel Access Scheme for Underwater Optical Wireless Communication Networks[C] // 2021 15th International Symposium on Medical Information and Communication Technology (ISMICT). 2021 : 65 – 69.

[21] YE H, LI G Y, JUANG B-H. Power of Deep Learning for Channel Estimation and Signal Detection in OFDM Systems[J]. IEEE Wireless Communications Letters, 2018, 7(1) : 114 – 117.

[22] 石佳, 黄爱萍, 陶林伟. 深度学习辅助水下光通信信道估计和信号检测 [J]. 中国激光, 2022, 49(17) : 110 – 117.

[23] 陈勇, 吴志倩, 刘焕淋, et al. 基于神经网络的可见光通信系统信道估计方法 [J]. 光学学报, 2023, 43(7) : 46 – 55.

[24] JIANG R, SUN C, ZHANG L, et al. Deep Learning Aided Signal Detection for SPAD-Based Underwater Optical Wireless Communications[J]. IEEE Access, 2020, 8 : 20363 – 20374.

[25] LU H, JIANG M, CHENG J. Deep Learning Aided Robust Joint Channel Classification, Channel Estimation, and Signal Detection for Underwater Optical Communication[J]. IEEE Transactions on Communications, 2021, 69(4) : 2290 – 2303.

[26] 卢怀因. 基于深度学习的水下无线光通信系统的信号检测技术研究 [D]. 广州 : 中山大学, 2021 年.

[27] 王新歌. 基于深度学习的水下无线光通信信道估计与信号检测研究 [D]. [S.l.]: 大连理工大学, 2023 年.

[28] MOBLEY C D. Light and Water: Radiative Transfer in Natural Waters[J]. Academic Press, 1994.

[29] SHIFRIN K S. Physical Optics of Ocean Water[J], 1988.

[30] GABRIEL C, KHALIGHI M A, BOURENNANE S, et al. Channel modeling for underwater optical communication[C] // IEEE Globecom Workshops. 2011 : 833 – 837.

[31] COCHENOUR B M, MULLEN L J, LAUX A E. Characterization of the Beam-Spread Function for Underwater Wireless Optical Communications Links[J]. IEEE Journal of Oceanic Engineering, 2009, 33(4) : 513 – 521.

[32] SMART J. Underwater optical communications systems part 1: variability of water optical parameters[C] // MILCOM 2005 - 2005 IEEE Military Communications Conference : Vol 2. 2005 : 1140 – 1146.

[33] GABRIEL C, KHALIGHI M A, BOURENNANE S, et al. Monte-Carlo-Based Channel Characterization for Underwater Optical Communication Systems[J]. IEEE/OSA Journal of Optical Communications and Networking, 2013, 5(1) : 1 – 12.

[34] LIU W, XU Z, YANG L. SIMO detection schemes for underwater optical wireless communication under turbulence[J]. Photonics Research, 2015, 3(3) : 48 – 53.

[35] JAMALI M V, MIRANI A, PARSAY A, et al. Statistical Studies of Fading in Underwater Wireless Optical Channels in the Presence of Air Bubble, Temperature, and Salinity Random Variations (Long Version)[J]. IEEE Transactions on Communications, 2018, PP(10) : 4706 – 4723.

[36] ANDREWS L C, PHILIPS R L, HOPEN C Y. Laser Beam Scintillation With Applications[J], 2001.

[37] DISSANAYAKE S D, ARMSTRONG J. Comparison of ACO-OFDM, DCO-OFDM and ADO-OFDM in IM/DD Systems[J]. Journal of Lightwave Technology, 2013, 31(7) : 1063 – 1072.

[38] TSONEV D, SINANOVIC S, HAAS H. Novel Unipolar Orthogonal Frequency Division Multiplexing (U-OFDM) for Optical Wireless[C] // IEEE. 2012.

[39] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep learning (Vol. 1)[M]. Cambridge : MIT Press, 2016.

[40] GOODFELLOW I, POUGETABADIE J, MIRZA M, et al. Generative adversarial nets[C] // Proceedings of the 27th International Conferenceon Neural Information Processing Systems (NIPS). 2014 : 2672– – 2680.

[41] MIRZA M, OSINDERO S. Conditional Generative Adversarial Nets[J]. Computer Science, 2014 : 2672 – 2680.

[42] ISOLA P, ZHU J Y, ZHOU T, et al. Image-to-Image Translation with Conditional Adversarial Networks[J]. Proceedings of IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.

[43] YE H, LIANG L, LI G Y, et al. Deep Learning based End-to-End Wireless Communication Systems with Conditional GAN as Unknown Channel[J]. IEEE Transactions on Wireless Communications, 2020, 19(5) : 3133 – 3143.

[44] 付重阳, 江鹏, 张宇, et al. 基于改进型 CGAN 的水声信号降噪模型 [J]. 计算机工程与设计, 2023, 44(5) : 1352 – 1358.

[45] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]. JMLR.org, 2015.

[46] CHOPRA S, HADSELL R, LECUN Y. Learning a similarity metric discriminatively, with application to face verification[C] // 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05) : Vol 1. 2005 : 539 – 546.

[47] 彭鑫. 基于卷积神经网络的特定场景下人脸识别研究 [D]. [S.l.] : 西安理工大学, 2019 年.

[48] 崔洲涓, 安军社, 张羽丰, et al. 面向无人机的轻量级 Siamese 注意力网络目标跟踪 [J]. 光学学报, 2020, 40(19) : 132 – 144.

[49] ZHU J Y, PARK T, ISOLA P, et al. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks[J]. IEEE, 2017.

[50] WANG C, YU Y-B. CycleGAN-VC-GP: Improved CycleGAN-based Non-parallel Voice Conversion[C] // 2020 IEEE 20th International Conference on Communication Technology (ICCT). 2020 : 1281 – 1284.

[51] 赵志明. 深度学习在自由空间涡旋光通信系统上的应用研究 [D]. [S.l.] : 西安电子科技大学, 2022.

[52] YIZHOU Y, BAOGUO L, QIANG X, et al. Pre Denoising Modulation Recognition Algorithm Based on CycleGAN[C] // 2022 5th International Conference on Communication Engineering and Technology (ICCET). 2022 : 77 – 80.

[53] HANZO L, KELLER T, MUENSTER M, et al. OFDM and MC-CDMA for Broadband Multi-User Communications, WLANs and Broadcasting[M]. USA : John Wiley & Sons, Inc., 2003.

[54] Vahid MOHAMMAD J, POOYA N, A JAWAD S. MIMO Underwater Visible Light Communications: Comprehensive Channel Study, Performance Analysis, and Multiple-Symbol Detection[J]. IEEE Transactions on Vehicular Technology, 2018, 67(9): 8223 – 8237.

[55] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929 – 1958.

[56] KINGMA D, BA J. Adam: A Method for Stochastic Optimization[J]. Computer Science, 2014.

[57] ZHANG J, WEN C K, JIN S, et al. Artificial Intelligence-aided Receiver for A CP-Free OFDM System: Design, Simulation, and Experimental Test[J]. IEEE Access, 2019, 7: 58901 – 58914.

# 致谢

时光荏苒，不觉间，四年的大学生活已步入尾声。思绪至此，不禁感慨良多。

寸草春晖，铭记于心。感谢一直在背后默默无闻支持我的家人，特别是我的父母。是您们的辛勤付出和默默奉献，让我能够安心追求学业，实现自己的梦想。您们的教诲和榜样，让我学会了做人的道理和处世的原则，成为了我人生中最宝贵的财富。在我遇到困难和挫折时，是您们给予我最大的支持和鼓励，让我能够重新振作，扬帆起航。您们的信任和理解，让我感受到了家庭的温暖和力量，也增强了我面对未来的信心和勇气。

承蒙教诲，谢意盈怀。感谢大学四年来辛勤授课的各位老师，正是您们的倾囊相授，使我不仅掌握了丰富的专业知识，更学会了如何深入思考、有效解决问题。您们严谨的治学态度和深厚的学术造诣，使我获益良多。感谢我大学生创新创业比赛的指导老师沈乐成老师，是您带我走进了学术研究的殿堂，为我解答了大学生涯的诸多疑惑。感谢我的导师江明老师，是您为我今后的学术道路打下了夯实的基础，在学术的海洋中，您如一座灯塔，在我遇到困难时为我指点迷津。感谢实验室的学长学姐，是你们耐心地为我解答学术上的疑惑，帮助我找到了前进的方向。你们丰富的经验和独到的见解，为我提供了宝贵的建议。

风雨同舟，谢意难表。感谢我的朋友们，我们一起度过了许多难忘的时光，分享着彼此的喜怒哀乐。你们的陪伴让我感到温暖，也让我更加珍惜这份友谊。感谢我的女朋友，你是我追梦路上的坚实后盾，更是我不断前行的动力。

在此，我再次向所有给予我帮助和支持的人表示衷心的感谢。你们的陪伴让我倍感温暖，你们的鼓励让我充满力量。展望未来，我将继续努力，不断提升自己的能力和素质，为实现更高的目标而拼搏。我会牢记你们的期望和嘱托，用实际行动回报你们的支持和信任！

韦子扬

2024 年 5 月 16 日

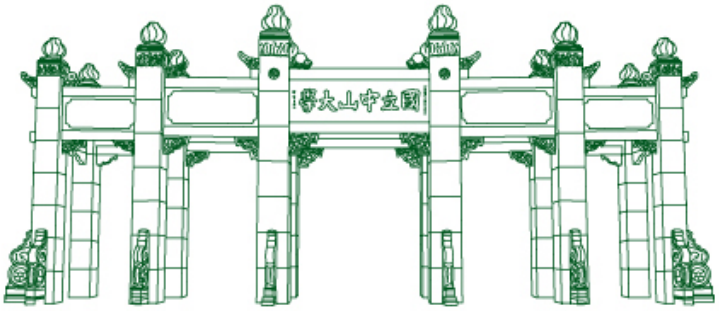


中山大學

SUN YAT-SEN UNIVERSITY